

Estudo de Caso 01: Comparação do IMC médio de alunos do PPGE-UFMG ao longo de dois semestres

EEE933 - Planejamento e Análise de Experimentos

Adonai Arruda, Alexandra Milaya Soto Aponte, João Paulo Gonçalves Simim, Yasmim Machado

14 de setembro de 2026

1 Resumo

Este relatório compara o Índice de Massa Corporal (IMC) médio de alunos de pós-graduação do PPGE-UFMG entre os semestres 2016-2 e 2017-2. Seguindo a orientação do enunciado, a comparação foi feita separadamente por sexo, em dois testes independentes: subpopulação masculina ($n = 21$ em cada semestre) e subpopulação feminina ($n = 7$ em 2016-2 e $n = 4$ em 2017-2). Em cada caso foram verificadas as premissas de normalidade (Shapiro-Wilk e gráficos quantil-quantil) e de homogeneidade de variâncias (Fligner-Killeen), ambas satisfeitas, o que levou à aplicação do teste t de Student bilateral para duas amostras independentes com $\alpha = 0,05$. Nos dois casos falhou-se em rejeitar a hipótese nula de igualdade de médias: para os homens, $p = 0,592$, diferença estimada de $0,65 \text{ kg/m}^2$ com IC 95% $[-1,78; 3,09]$; para as mulheres, $p = 0,086$, diferença estimada de $2,64 \text{ kg/m}^2$ com IC 95% $[-0,45; 5,73]$. A análise de poder mostrou, porém, que, para o menor efeito de interesse prático adotado ($\delta^* = 1 \text{ kg/m}^2$), o poder dos testes é de apenas cerca de 13% (masculino) e 10% (feminino), de modo que a ausência de rejeição não deve ser interpretada como evidência de que o IMC médio se manteve inalterado. Discutem-se o tamanho amostral necessário e melhorias de desenho para estudos futuros.

1.1 Papéis desempenhados pelos membros da equipe

Membro	Papel
Adonai Arruda	Coordenador e Monitor: estruturação do repositório, análise inicial em R e conversão para R Markdown
Alexandra Milaya Soto Aponte	Relatora e Verificadora: pré-processamento dos dados, verificação das premissas, testes de hipóteses, análise de poder e redação das seções técnicas
Yasmim Machado	Verificadora: revisão da análise e do texto final
João Paulo Gonçalves Simim	Verificador: compilação independente do relatório, revisão técnica, redação do resumo, das conclusões e das sugestões de melhoria

2 Projeto experimental

2.1 Objetivo do Experimento e Hipóteses a serem Testadas

O objetivo principal deste experimento é verificar se existe diferença estatisticamente significativa no IMC médio dos alunos de pós-graduação do PPGE-UFMG entre os semestres 2016-2 e 2017-2. Para tanto, as

amostras foram separadas em subcategorias de análise classificadas por sexo e semestre:

- Homens em 2016-2 vs. Homens em 2017-2
- Mulheres em 2016-2 vs. Mulheres em 2017-2

Não se realizou um teste com as duas subpopulações agregadas: como o IMC médio difere substancialmente entre os sexos, uma comparação agregada seria influenciada pela proporção de homens e mulheres em cada turma, e não apenas por uma eventual mudança de IMC ao longo do tempo (confundimento por sexo).

Para cada subpopulação (separada por sexo), definem-se as seguintes hipóteses bilaterais, por não haver razão teórica prévia para supor a direção de uma eventual diferença do IMC médio da população de 2016-2 em relação à população de 2017-2:

- **Hipótese Nula** (H_0): Não há diferença na média do IMC entre os alunos de 2016-2 e 2017-2.
- **Hipótese Alternativa** (H_1): Há diferença significativa na média do IMC entre os semestres 2016-2 e 2017-2.

$$\begin{cases} H_0 : \mu_{2016} - \mu_{2017} = 0 \\ H_1 : \mu_{2016} - \mu_{2017} \neq 0 \end{cases}$$

2.2 Descrição da Coleta e Consolidação dos Dados

Por se tratar de um estudo retrospectivo, isto é, uma análise baseada em dados previamente coletados, a definição teórica do tamanho amostral e a estimação prévia do tamanho do efeito não puderam ser planejadas ativamente antes da coleta. Dessa forma, essas métricas serão reportadas e discutidas durante a apresentação dos resultados dos testes de hipótese. Esta subseção é dedicada exclusivamente ao procedimento de filtragem, tratamento e consolidação das bases de dados.

Os dados do semestre 2016-2 foram recuperados do arquivo `data/imc_20162.csv`, enquanto os do semestre 2017-2 correspondem ao arquivo `data/CS01_20172.csv`. Conforme especificado no enunciado, a base de 2016-2 inclui registros de turmas de graduação, e ambas as tabelas possuem divergências na estrutura das colunas. A consolidação dos dados exigiu as seguintes etapas de pré-processamento:

1. **Filtragem dos dados de 2016-2:** isolamento dos alunos pertencentes à pós-graduação (`Course == "PPGEE"`).
2. **Padronização dos nomes das colunas:** renomeação dos campos no arquivo de 2017-2 (`height.m` → `Height.m` e `Sex` → `Gender`) para alinhar com o esquema do arquivo de 2016-2.
3. **Conversão para tipo numerico**
4. **Cálculo do IMC:** criação da variável BMI em ambas as tabelas, aplicando a fórmula:

$$\text{BMI} = \frac{\text{Peso}}{\text{Altura}^2}$$

5. **Estruturação por subpopulações:** separação das observações por sexo e semestre para a criação dos conjuntos agregados que compõem os grupos de análise, alocados nas seguintes variáveis:
 - `fem_2016`, `fem_2017`: subpopulações femininas dos semestres 2016-2 e 2017-2, respectivamente.
 - `masc_2016`, `masc_2017`: subpopulações masculinas dos semestres 2016-2 e 2017-2, respectivamente.
 - `fem`, `masc`: agregados das subpopulações femininas e masculinas, englobando ambos os semestres.
 - `todos`: tabela consolidada com a totalidade dos dados, classificados por sexo e semestre.

3 Análise Exploratória dos Dados

A fim de compreender o comportamento dos dados, foi realizada uma exploração inicial por meio de um gráfico de *boxplot* para comparar a distribuição do IMC entre as subpopulações de cada semestre.




Figura 1: Distribuição do IMC por Sexo e Semestre

Em seguida, os principais parâmetros estatísticos (tamanho amostral n , média e desvio-padrão) de cada subcategoria foram calculados e resumidos na Tabela 1.

Grupo	n	Média	Desvio Padrão
Feminino 2016-2	7	21.08	2.42
Feminino 2017-2	4	18.45	1.60
Masculino 2016-2	21	24.94	4.32
Masculino 2017-2	21	24.29	3.44

Tabela 1: Estatísticas descritivas do IMC por subamostra

4 Análise Estatística

4.1 Validação das premissas do modelo

O teste t para duas amostras independentes assume três premissas: independência das observações, normalidade dos resíduos em cada grupo e homogeneidade de variâncias entre os grupos. As duas últimas são verificáveis a partir dos dados e foram testadas, nesta ordem, para cada subpopulação. A independência, por sua vez, não é uma propriedade testável a partir das observações e sim uma consequência do desenho do estudo: aqui ela é assumida com base no fato de que as duas amostras de cada sexo correspondem a coortes distintas (turmas de 2016-2 e de 2017-2), coletadas em momentos diferentes e sem pareamento entre indivíduos. Uma ressalva deve ser registrada: como os dados são anonimizados, não é possível excluir que um mesmo aluno esteja presente nas duas turmas, o que introduziria dependência entre as amostras. Essa limitação é retomada na seção de melhorias do experimento.

Genero	Semestre	p-valor
F	2016-2	0.467
M	2016-2	0.127
F	2017-2	0.037
M	2017-2	0.621

Tabela 2: Resultado do p-valor para o teste de Shapiro-Wilk

4.1.1 Normalidade

O teste de Shapiro-Wilk foi realizado para cada uma das subamostras em análise. Os resultados seguem na Tabela 2.

Os resultados indicam que as amostras masculinas (2016-2 e 2017-2) e a amostra feminina de 2016-2 apresentam comportamento compatível com a distribuição normal ($p\text{-valor} > 0,05$), não permitindo a rejeição da hipótese nula de normalidade.

Por outro lado, a amostra feminina do semestre 2017-2 (fem_2017) apresentou um $p\text{-valor}$ de 0,036, ficando abaixo do nível de significância adotado ($\alpha = 0,05$). Isso indica não há evidências estatísticas suficientes para assumir a normalidade desse subgrupo. No entanto, por se tratar de um $p\text{-valor}$ marginalmente próximo ao limiar de 0,05, é plausível supor que a presença de algum ponto discrepante (outlier) ou a assimetria da amostra esteja afetando o teste. Ao analisar o boxplot da Figura 1, não se observa um outlier extremo para este subgrupo, contudo nota-se que o valor máximo está relativamente afastado da média. Por esse motivo, fez-se necessária uma investigação complementar por meio do gráfico quantil-quantil (Q-Q plot).




Figura 2: Gráficos quantil-quantil do IMC do sub grupo feminino 2017

O gráfico quantil-quantil (Q-Q plot) indica que a violação da premissa de normalidade para a amostra feminina 2017-2 é provocada por apenas um único valor discrepante. Dessa forma, é razoável assumir a premissa de normalidade para as análises subsequentes, uma vez que o teste t de Student é robusto a pequenas desvios da distribuição normal.

Tal assunção é interessante, uma vez que o teste t de Student tradicional apresenta a vantagem de proporcionar maior poder de teste em relação ao teste de Welch, quando a premissa de homogeneidade de variâncias é de fato satisfeita.

4.1.2 Igualdade de Variância

Grupo de Comparação	Estatística (Chi ²)	p-valor
Feminino (2016-2 vs 2017-2)	0.709	0.400
Masculino (2016-2 vs 2017-2)	0.083	0.774

Tabela 3: Resultado do teste de Fligner-Killeen para igualdade de variâncias entre semestres

De acordo com os resultados do teste de Fligner-Killeen apresentados na Tabela 3, tanto a subpopulação feminina (p -valor $> 0,05$) quanto a masculina (p -valor $> 0,05$) mantiveram a premissa de homocedasticidade. Com a confirmação da igualdade de variâncias e da normalidade, o teste t de Student para amostras independentes com variâncias iguais é o procedimento adequado para a comparação das médias do IMC entre os semestres 2016-2 e 2017-2.

4.1.3 Efeito minimamente relevante (δ^*)

O valor do menor efeito de interesse prático foi fixado *a priori*, antes do exame dos dados, em $\delta^* = 1 \text{ kg/m}^2$, tal valor foi adotado nos 2 casos analisados, por ser a relevância prática uma propriedade da grandeza medida e não da dispersão de cada subamostra. Essa escolha não pretende representar um limiar de relevância clínica ou prática específico, mas sim estabelecer uma referência comum e consistente, que permite comparar a sensibilidade do teste entre os dois grupos em igualdade de condições, evitando que diferenças nos resultados da discussão de potência decorram da escolha de valores de referência distintos para cada subpopulação, e não de diferenças reais em seus tamanhos amostrais ou variabilidades.

4.1.4 Nível de significância e tamanho amostral

Os testes foram executados com `conf.level = 0.95`, o que corresponde a um nível de significância $\alpha = 0,05$.

4.2 Teste de Hipóteses

Os testes de hipótese foram realizados seguindo as hipóteses definidas na seção de Objetivo do Experimento e Hipóteses a serem Testadas. Os testes foram realizados para obter informações sobre a inferência da diferença da média do IMC para as subpopulações femininas 2016-2 vs. 2017-2, e repetidos para as subpopulações masculinas 2016-2 vs. 2017-2. Portanto, esta seção se divide em dois casos: subpopulação masculina e subpopulação feminina

4.2.1 Caso 1: Subpopulação Masculina

```
##
## Two Sample t-test
##
## data:  masc_2016$BMI and masc_2017$BMI
## t = 0.53979, df = 40, p-value = 0.5923
## alternative hypothesis: true difference in means is not equal to 0
## 95 percent confidence interval:
##  -1.784943  3.085836
## sample estimates:
## mean of x mean of y
##  24.93595  24.28551
```

O teste resultou em $p = 0,5923$, sendo o intervalo de confiança de 95% para a diferença entre as médias: $[-1,7849; 3,0858]$ kg/m², e médias amostrais de 24,9360 kg/m² (2016-2) e 24,2855 kg/m² (2017-2). Como o intervalo de confiança contém o valor zero e, o p -valor obtido é maior que $\alpha = 0,05$, falhou-se em rejeitar a hipótese nula, não havendo evidências estatísticas suficientes para afirmar que o IMC médio da subpopulação masculina difere entre os semestres 2016-2 e 2017-2.

4.2.2 Caso 2: População Feminina

```
##
## Two Sample t-test
##
## data: fem_2016$BMI and fem_2017$BMI
## t = 1.9308, df = 9, p-value = 0.08556
## alternative hypothesis: true difference in means is not equal to 0
## 95 percent confidence interval:
## -0.4527037 5.7283762
## sample estimates:
## mean of x mean of y
## 21.08443 18.44660
```

O teste resultou em $p = 0,08556$, sendo o intervalo de confiança de 95% para a diferença entre as médias: $[-0,4527; 5,7284]$ kg/m², com médias amostrais de 21,0844 kg/m² (2016-2) e 18,4466 kg/m² (2017-2). Como o intervalo de confiança contém o valor zero, e o p -valor obtido, embora relativamente próximo de $\alpha = 0,05$, ainda é maior que esse limiar, falhou-se em rejeitar a hipótese nula, não havendo evidências estatísticas suficientes para afirmar que o IMC médio da subpopulação feminina difere entre os semestres 2016-2 e 2017-2.

4.3 Resultados e Discussões

4.3.1 Discussão sobre o Teste de Hipóteses

O objetivo deste experimento era verificar se existia diferença significativa no IMC médio entre duas populações de estudantes: alunos de pós-graduação do PPGEU-UFMG nos semestres 2016-2 e 2017-2.

Os testes foram realizados sobre essas populações, separadas por gênero. Em ambos os casos, falhou-se em rejeitar a hipótese nula, não havendo evidências estatísticas suficientes para afirmar que o IMC médio difere entre os semestres, tanto para a subpopulação masculina quanto para a feminina. No entanto, devido ao tamanho reduzido de cada subamostra, é interessante realizar uma análise de poder do teste, que pode ajudar a avaliar a possibilidade de um Erro Tipo II, isto é, a hipótese de que se falhou em rejeitar H_0 mesmo havendo, de fato, uma diferença real entre as populações. Por esse motivo, a seção a seguir traz essa discussão à tona.

4.3.2 Discussão sobre o Poder do Teste

É convencional definir o poder estatístico em 80% ($1 - \beta = 0,80$). Contudo, por se tratar de um estudo retrospectivo, em que os dados já haviam sido previamente coletados, não houve controle sobre o tamanho amostral para garantir essa potência *a priori*.

Para poder levar a cabo o cálculo de poder de teste devemos conhecer a variância populacional σ^2 , como a mesma é desconhecida, é necessário estimá-la a partir dos dados amostrais. Assumindo a premissa de igualdade de variância entre as subpopulações ($\sigma_1^2 \approx \sigma_2^2$), confirmada pelo teste de Fligner-Killeen, utiliza-se o estimador ponderado da variância agrupada (S_p^2):

$$S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2} \quad (1)$$

em que S_1^2 e S_2^2 são as variâncias amostrais das subpopulações de 2016-2 e 2017-2, e n_1, n_2 os respectivos tamanhos amostrais. O desvio-padrão agrupado ($S_p = \sqrt{S_p^2}$) é então utilizado como parâmetro de dispersão no cálculo do poder do teste.

Desvio Padrão - masculino - : 3.905

Desvio Padrão - feminino - : 2.18

Poder para detectar delta* = 1 (masculino): 0.125

Poder para detectar delta* = 1 (feminino): 0.101

Observa-se que, em ambos os casos, o arranjo amostral disponível (com $n_{masc} = 42$ e $n_{fem} = 11$) não teria sensibilidade suficiente para detectar, com poder de 80%, uma diferença da magnitude que se definiu como referência mínima de interesse ($\delta^* = 1 \text{ kg/m}^2$). De fato, ao calcular diretamente o poder do teste para detectar especificamente $\delta^* = 1 \text{ kg/m}^2$, obtém-se um poder de apenas 12,5% (masculino) e 10,1% (feminino), valores bem abaixo do limiar convencional de 80% considerado adequado.

5 Conclusões e Recomendações

d de Cohen - masculino: 0.17

d de Cohen - feminino: 1.21

Para as duas subpopulações analisadas, falhou-se em rejeitar H_0 : não há evidência estatística, ao nível de 5%, de que o IMC médio dos alunos do PPGEE tenha mudado entre 2016-2 e 2017-2. Esse resultado, contudo, deve ser lido à luz do poder dos testes. Para o menor efeito de interesse prático adotado ($\delta^* = 1 \text{ kg/m}^2$), o poder é de aproximadamente 13% no caso masculino e 10% no feminino, o que corresponde a uma probabilidade de erro do tipo II próxima de 90%. Em outras palavras, mesmo que uma diferença dessa magnitude existisse, os testes dificilmente a detectariam com os tamanhos amostrais disponíveis. A não rejeição de H_0 não é, portanto, evidência de ausência de diferença.

Os dois casos contam, ainda, histórias distintas que o p -valor sozinho não revela. No caso masculino, a diferença estimada é pequena ($0,65 \text{ kg/m}^2$; d de Cohen $\approx 0,17$) e o intervalo de confiança está praticamente centrado no zero, o que é compatível com ausência de efeito relevante. No caso feminino, a diferença estimada é grande ($2,64 \text{ kg/m}^2$; $d \approx 1,2$) e o intervalo de confiança é largo e quase inteiramente positivo, o que sugere um possível efeito que a amostra de 11 pessoas não permite confirmar. Recomenda-se, assim, que uma eventual replicação priorize a ampliação da amostra feminina.

5.1 Sugestões de melhoria do experimento

5.1.1 Menor Diferença Detectável

Considerando o baixo poder de teste calculado na seção anterior, aqui se pretende discutir:

1. o número de observações necessárias para atingir o poder de teste de 80%;

2. a menor diferença detectável para um poder de teste de 80% e o nível de significância em $\alpha = 0,05$, considerando o arranjo amostral disponível.

A função empregada para esse cálculo, porém, depende do balanceamento amostral de cada subpopulação: para a subpopulação masculina, balanceada ($n_{2016} = n_{2017} = 21$), utiliza-se `power.t.test()`; para a feminina, desbalanceada ($n_{2016} \neq n_{2017}$), utiliza-se `pwr.t2n.test()` do pacote `pwr`, que admite tamanhos amostrais distintos entre os dois grupos.

Subpopulação Masculina

```
## Número de observações necessário (delta* = 1) - masculina: 240.3
```

```
## Menor diferença detectável - masculina: 3.46 kg/m2
```

Subpopulação Feminina

```
## Número de observações necessário (delta* = 1) - feminino: 75.6
```

```
## Menor diferença detectável - feminina: 4.3 kg/m2
```

Essa limitação reforça a recomendação de que estudos futuros sobre o tema considerem um planejamento amostral prévio, com cálculo de tamanho de amostra baseado em um δ^* definido antes da coleta, de modo a garantir poder adequado para detectar efeitos de magnitude prática relevante.

Além do dimensionamento amostral, o próprio desenho do estudo poderia ser aprimorado em pontos que afetam diretamente a validade e o poder da comparação:

- **Desenho pareado ou longitudinal.** Acompanhar os mesmos alunos ao longo dos semestres e comparar as diferenças individuais elimina a variabilidade entre indivíduos, que hoje domina a variância do IMC, e aumenta substancialmente o poder do teste para um mesmo número de participantes.
- **Garantia de independência entre coortes.** Registrar um identificador anônimo por aluno permitiria excluir (ou tratar como pareados) os indivíduos presentes nas duas turmas, eliminando a ressalva feita na verificação das premissas.
- **Medição padronizada.** Peso e altura autorrelatados estão sujeitos a arredondamento e viés; uma medição com protocolo único reduziria o erro de medida.
- **Controle de covariáveis.** Registrar idade e situação no curso (ingressante ou veterano) permitiria blocagem ou ajuste por esses fatores, isolando melhor o efeito do tempo.
- **Escolha da variável de resposta.** O IMC é um indicador indireto e limitado de composição corporal; se a pergunta de interesse for saúde ou hábitos de vida, medidas complementares seriam mais informativas.

5.2 Declaração sobre o Uso de IA Generativa e Tecnologias Assistidas por IA no Processo de Elaboração do Relatório

Durante a preparação deste trabalho, os autores utilizaram o Claude (Anthropic) para redigir a versão inicial das seções descritivas deste relatório, a partir dos resultados registrados como comentários no script de análise `processamento_separado.R`. Após utilizar essa ferramenta, os autores revisaram, editaram e finalizaram o conteúdo conforme necessário e assumem total responsabilidade pelo conteúdo da publicação.

Também foi utilizada IA para auxiliar na formatação do texto, incluindo a inclusão de bibliotecas que ajudam na visualização de gráficos e tabelas apresentados no relatório. Da mesma forma, foi solicitado apoio para revisar o chunk de setup do R Markdown, de modo a garantir a instalação das bibliotecas necessárias para que o arquivo compilasse sem erros.

Por fim, nas seções sobre o Poder do Teste e sobre a Menor Diferença Detectável, foi questionado qual função poderia ser utilizada para realizar o cálculo de poder no caso de populações não balanceadas (subpopulação feminina, com $n_{2016} = 7$ e $n_{2017} = 4$), uma vez que esse caso não foi discutido (em R) durante as aulas. A resposta indicou a função `pwr.t2n.test()` do pacote `pwr`, que foi adotada tanto no cálculo do poder atual quanto no da menor diferença detectável, em substituição a `power.t.test()`, que assume grupos de tamanhos iguais.

Adicionalmente, o Claude (Anthropic) foi utilizado para (i) compilar o R Markdown em ambiente independente e verificar a reprodutibilidade dos resultados; (ii) recalcular, de forma independente, as estatísticas descritivas, os testes e a análise de poder para conferência dos valores reportados; e (iii) apoiar a redação do resumo, das conclusões e das sugestões de melhoria do experimento. Todo o conteúdo gerado com apoio de IA foi revisado pelos autores, que assumem integral responsabilidade pelo relatório.