

Estudo de Caso 02: Avaliação e comparação do retorno médio de ações

EEE933 - Planejamento e Análise de Experimentos — PPGE/UFMG

Adonai Arruda, Alexandra Milaya Soto Aponte, João Paulo Gonçalves Simim, Yasmim Machado

05 de outubro de 2026

1 Resumo

Um investidor deseja aplicar todo o seu capital em uma única ação durante o próximo mês e dispõe dos preços de fechamento de cinco ações nos últimos 36 meses. Os preços foram convertidos em 35 retornos mensais por ação e comparados por meio de testes de hipóteses: ANOVA (teste global), seguido do teste de Dunnnett (todas contra a ação de maior média amostral) como teste confirmatório; o teste de Tukey (todos contra todos) foi usado apenas em caráter exploratório. O teste global rejeitou a igualdade das médias ($p = 1,32 \times 10^{-4}$; $\alpha = 0,05$). O teste de Dunnnett descartou V2, V4 e V5 ($p < 0,05$), mas não distinguiu V3 de V1. Como mais de uma ação se destacou, adotou-se como critério de desempate a análise de risco e variabilidade: V1 tem o maior retorno médio, o menor desvio-padrão, a maior razão retorno/risco e a menor perda mensal, dominando V3 em todos os indicadores. A ação **V1** foi a recomendada, com a ressalva de que o experimento tem potência limitada para separá-la de V3.

2 Introdução

Um investidor deseja aplicar todo o seu capital em **uma única ação** no próximo mês, buscando o maior retorno mensal. Foram coletados os preços de fechamento de cinco ações nos últimos 36 meses. O objetivo deste relatório é:

1. determinar qual ação tem maior potencial de retorno mensal médio;
2. caso mais de uma ação se destaque, apresentar evidências adicionais para escolher uma única ação.

3 Planejamento do Experimento

3.1 Objetivos do Experimento (Hipóteses a serem testadas)

Seja μ_j o retorno mensal médio da ação j ($j = 1, \dots, 5$). A inferência é feita com um teste global seguido de **um único** procedimento de comparações múltiplas, escolhido de acordo com a pergunta do experimento; as demais análises são exploratórias ou descritivas.

1. **Teste global (ANOVA):** segundo Montgomery (2017), o modelo de um fator é

$$\begin{cases} H_0 : \tau_j = 0, \quad \forall j \in \{1, 2, \dots, 5\} \\ H_1 : \exists j : \tau_j \neq 0 \end{cases}.$$

As hipóteses são $H_0 : \mu_1 = \dots = \mu_5$ (todos os efeitos τ_j são nulos) contra H_1 : ao menos uma média difere. Se H_0 for rejeitada, existe ao menos uma ação cujo retorno médio é diferente das demais, mas o teste não indica qual.

	Media	DP	Mediana	Minimo	Maximo
V1	1,340	0,927	1,275	-0,266	3,359
V2	0,434	0,864	0,429	-2,240	1,823
V3	0,835	0,968	0,721	-0,812	2,940
V4	0,247	1,179	0,181	-1,574	2,376
V5	0,709	1,058	0,819	-2,899	2,650

Tabela 1: Estatísticas descritivas dos retornos mensais (valores em porcentagem).

2. **Teste de Tukey (exploratório; Tukey, 1949):** compara todos os pares de ações (j, l) ($H_0 : \mu_j = \mu_l$ contra $H_1 : \mu_j \neq \mu_l$). É usado apenas para visualizar o panorama geral das diferenças; nenhuma decisão é tomada com base nele.
3. **Teste de Dunnett (confirmatório; Dunnett, 1955):** a pergunta do experimento é “qual ação tem o maior retorno?”, uma comparação do tipo *todas contra uma*. Toma-se como referência a ação de maior média amostral (V1) e testa-se $H_0 : \mu_j = \mu_1$ contra $H_1 : \mu_j \neq \mu_1$ para cada $j \neq 1$. Com apenas $k - 1$ comparações, é o procedimento de maior potência para essa pergunta. Registra-se que a referência foi escolhida após observar os dados, o que é uma limitação declarada do experimento.
4. **Critério de desempate (análise de risco e variabilidade):** se mais de uma ação não for distinguível da referência, não se realiza um novo teste de hipóteses sobre as mesmas médias, pois isso inflaria o erro tipo I (ver Seção 7). Em vez disso, as candidatas são comparadas por indicadores de risco: desvio-padrão dos retornos, razão retorno/risco, pior mês e proporção de meses positivos. Escolhe-se a ação que domina as demais nesses critérios. O intervalo de confiança da diferença entre as candidatas é reportado apenas como medida do tamanho do efeito.

O nível de significância adotado em todos os testes é $\alpha = 0,05$.

3.2 Descrição da coleta e consolidação dos dados (Pré-processamento)

O arquivo `DadosAcoesGrupoE.csv` não possui cabeçalho. Tem 36 linhas (meses) e 5 colunas (ações, nomeadas V1 a V5 pelo R). A linha 1 é o mês mais recente e a linha 36 é o mais distante.

Adota-se a notação do enunciado: $P_{i,j}$ é o conteúdo da posição (i, j) do arquivo, isto é, o preço de fechamento da ação j ($j = 1, \dots, 5$) no período i ($i = 1, \dots, 36$). Assim, i indexa os meses (linhas) e j indexa as ações (colunas), e a mesma convenção vale para os retornos $r_{i,j}$ e para o modelo da ANOVA, em que τ_j é o efeito da ação j .

O pré-processamento segue as simplificações do enunciado. A primeira é que o preço de abertura de um mês é idêntico ao preço de fechamento do mês anterior. Com isso, o retorno mensal pode ser calculado apenas com os preços de fechamento, e o retorno da ação j no período i é

$$r_{i,j} = \frac{P_{i,j} - P_{i+1,j}}{P_{i+1,j}}$$

em que $P_{i+1,j}$ é o fechamento do mês imediatamente anterior ao mês i (a linha seguinte, pois a ordenação é do mais recente para o mais antigo). A segunda simplificação é que as ações podem ser compradas de forma fracionária, de modo que todo o capital é aplicado na ação escolhida. Por isso, o ganho do investidor é proporcional ao retorno relativo $r_{i,j}$, independentemente do preço unitário de cada ação, e as ações podem ser comparadas diretamente pelos seus retornos. A linha mais antiga não possui mês anterior, portanto obtêm-se $n = 35$ retornos por ação, totalizando 175 observações.

4 Análise Exploratória dos Dados

A Figura 1 mostra a distribuição dos retornos de cada ação.




Figura 1: Distribuição dos retornos mensais por ação (em %).

	V1	V2	V3	V4	V5
V1	1,00	0,13	-0,24	-0,21	-0,16
V2	0,13	1,00	0,09	0,01	-0,11
V3	-0,24	0,09	1,00	0,08	0,04
V4	-0,21	0,01	0,08	1,00	0,24
V5	-0,16	-0,11	0,04	0,24	1,00

Tabela 2: Correlação entre os retornos das ações (mesmos meses).

A Tabela 1 apresenta as estatísticas descritivas dos retornos mensais de cada ação; todos os valores estão em porcentagem. A média indica o retorno esperado ao mês, e o desvio-padrão mede a variabilidade dos retornos, ou seja, o risco. Mediana, mínimo e máximo ajudam a identificar assimetria e valores extremos.

Considerando apenas a média, a ação com maior retorno é a **V1** (1,340% ao mês), seguida por V3 (0,835%) e V5 (0,709%). V2 e V4 têm as menores médias (0,434% e 0,247%). V4 é também a ação de maior dispersão (desvio-padrão de 1,179%). Apenas as médias amostrais, porém, não permitem concluir que as diferenças são reais, o que motiva os testes seguintes.

Como todas as ações são observadas nos mesmos meses, verifica-se também se há um movimento comum de mercado entre elas (Tabela 2), o que afetaria a premissa de independência entre os grupos.

As correlações da Tabela 2 são todas baixas (em módulo, no máximo 0,24). Isso indica que não há um movimento comum de mercado forte entre essas ações nos mesmos meses, o que é coerente com tratar as colunas como amostras aproximadamente independentes.

	p_valor
V1	0,5638
V2	0,0878
V3	0,4969
V4	0,0980
V5	0,0239

Tabela 3: Shapiro-Wilk por ação (H0: retornos normais).

5 Análise Estatística

As próximas seções explicam os testes realizados e os resultados obtidos. Os testes seguem Montgomery (2017) e o material da disciplina; a análise foi feita em R (R Core Team, 2025).

5.1 Modelo ANOVA e validação das premissas

5.1.1 Normalidade




Figura 2: QQ-plot dos resíduos do modelo.

O teste de Shapiro-Wilk sobre os resíduos do modelo tem p-valor de 0,2469, portanto não rejeita a normalidade ao nível de 5%. O QQ-plot (Figura 2) confirma o resultado: os pontos acompanham a reta e ficam dentro da banda de confiança. Avaliando cada ação separadamente (Tabela 3), apenas V5 rejeita a normalidade ($p = 0,0239$); como a premissa se refere aos resíduos do modelo e o ANOVA é robusto a desvios moderados de normalidade com grupos balanceados, a premissa é considerada atendida.

5.1.2 Homoscedasticidade

O teste de Fligner-Killeen (robusto à não normalidade) tem $p = 0,1936$ e não rejeita a igualdade das variâncias. O gráfico de resíduos contra ajustados (Figura 3) não mostra padrão de funil, a dispersão é semelhante entre




Figura 3: Resíduos do modelo contra valores ajustados.

as ações. A premissa de homoscedasticidade é considerada satisfeita.

5.1.3 Independência

Os dados são séries mensais da mesma ação, então foi verificada a autocorrelação temporal (os retornos foram revertidos para a ordem cronológica). Além disso, como todas as ações são observadas nos mesmos meses, avaliou-se se o mês funciona como um bloco, isto é, se há um efeito comum de mercado que justificaria uma ANOVA em blocos.

O teste de Box-Pierce (6 defasagens) não indica autocorrelação em nenhuma ação (menor p-valor = 0,5930), e o teste de Durbin-Watson sobre os resíduos do modelo tem $p = 0,6820$. O efeito de bloco “mês” não é significativo ($p = 0,5370$), coerente com as baixas correlações entre ações da Tabela 2. A premissa de independência é considerada atendida, e o modelo de um fator sem bloco é mantido.

5.2 Teste ANOVA

O primeiro teste avalia se as médias de retorno das cinco ações são iguais. As hipóteses são:

- H_0 : as médias de retorno das cinco ações são iguais ($\mu_1 = \mu_2 = \mu_3 = \mu_4 = \mu_5$, ou seja, $\tau_j = 0$ para todo j);
- H_1 : ao menos uma ação tem retorno médio diferente das demais ($\exists j : \tau_j \neq 0$).

[1] 0,0001323065

O p-valor de $1,32 \times 10^{-4}$ é menor que $\alpha = 0,05$, portanto **rejeita-se H_0** : existe ao menos uma ação com retorno médio diferente das demais. Como o ANOVA não diz quais ações diferem, seguem-se as comparações múltiplas.

5.3 Teste de Tukey

Em caráter exploratório, o teste de Tukey (1949) compara todos os pares de ações, controlando o erro global da família de 10 comparações.




Figura 4: Intervalos de confiança simultâneos de 95% (Tukey) para as diferenças entre todos os pares de ações.

Na Figura 4, os intervalos de confiança que não contêm o zero indicam diferença significativa. V2 e V4 têm retorno médio significativamente menor que V1 ($p = 0,0020$ e $p = 9,86 \times 10^{-5}$). Já V3 e V5 **não podem ser distinguidas de V1** ao nível de 5% ($p = 0,2233$ e $p = 0,0697$). Isso não prova que as médias são iguais, apenas que, com a correção para comparações múltiplas, os dados não trazem evidência de diferença. Note que entre V2, V3, V4 e V5 também não há diferença significativa entre si. Esse panorama orienta a escolha da referência para o teste confirmatório, mas as decisões são tomadas apenas com base nele (Seção 5.4).

5.4 Teste de Dunnett

Este é o teste confirmatório. Como V1 tem a maior média amostral, ela é tomada como referência. Em vez de comparar todos os pares, o Dunnett compara apenas V1 contra cada uma das outras ($k - 1 = 4$ comparações), com controle do erro *family-wise* em 5%.

A Figura 5 e os p-valores ajustados mostram que três ações têm retorno médio significativamente menor que a referência: V2 e V4 (ambas com $p < 0,001$) e V5 ($p = 0,0326$). Como as três rejeitam a igualdade com V1 ao nível de 5%, **V2, V4 e V5 são descartadas**. V3, por outro lado, apresenta $p = 0,1176$, e o intervalo de confiança da diferença ($V3 - V1$) contém o zero; portanto, não é possível afirmar que seu retorno médio difere do de V1. Assim, **V1 e V3 se destacam** como resposta à primeira pergunta do experimento, e a escolha entre elas passa ao critério de desempate.




Figura 5: Intervalos de confiança simultâneos de 95% (Dunnett) para as diferenças de cada ação em relação a V1.

	Media_pct	DP_pct	Razao	Pior_mes	Prop_meses_positivos
V1	1,340	0,927	1,445	-0,266	0,914
V2	0,434	0,864	0,502	-2,240	0,714
V3	0,835	0,968	0,863	-0,812	0,829
V4	0,247	1,179	0,210	-1,574	0,543
V5	0,709	1,058	0,670	-2,899	0,829

Tabela 4: Retorno médio, risco e razão retorno/risco.

5.5 Tamanho do efeito entre V1 e V3

Restam duas candidatas, V1 e V3. Um novo teste de hipóteses entre elas não seria válido: a comparação foi selecionada após examinar todas as outras, e um teste t sem correção nessa posição não controla o erro tipo I (Seção 7). O intervalo de confiança de 95% da diferença $\mu_1 - \mu_3$ é apresentado apenas como estimativa do **tamanho do efeito**, para dimensionar o que está em jogo no desempate.

A diferença estimada (Figura 6) é de 0,51 pontos percentuais (p.p.) ao mês a favor de V1, com IC de 95% de 0,05 a 0,96 p.p. O limite inferior próximo de zero mostra que o efeito, embora favorável a V1, é pequeno em relação à variabilidade mensal.

5.6 Critério de desempate: análise de risco e variabilidade

Como os testes de hipóteses não distinguem V1 de V3, a escolha entre elas é feita por um critério econômico: entre duas ações com retorno médio estatisticamente indistinguível, o investidor racional prefere a de menor risco. Comparam-se o desvio-padrão dos retornos, a razão retorno/risco (sem taxa livre de risco), o pior mês e a proporção de meses positivos.




Figura 6: Intervalo de confiança de 95% da diferença de retorno médio entre V1 e V3.

A Tabela 4 resume o desempenho de cada ação em termos de retorno e risco. As colunas são:

- **Media_pct:** retorno médio mensal, em porcentagem ($\bar{r}_j = \frac{1}{n} \sum_i r_{i,j}$). É o retorno que se espera, em média, ao investir na ação por um mês, e é a medida que os testes de hipóteses comparam.
- **DP_pct:** desvio-padrão dos retornos mensais, em porcentagem. Mede a variabilidade do retorno em torno da média e é usado aqui como medida de risco: quanto maior, mais incerto é o resultado do próximo mês.
- **Razao:** razão retorno/risco, calculada como média dividida pelo desvio-padrão ($\bar{r}_j/s_j$). Indica quanto retorno médio a ação entrega por unidade de risco assumido. É semelhante ao índice de Sharpe, mas sem descontar a taxa livre de risco. Não tem unidade, e quanto maior, melhor.
- **Pior_mes:** menor retorno mensal observado nos 35 meses, em porcentagem. Mostra a pior perda histórica em um único mês.
- **Prop_meses_positivos:** proporção de meses em que o retorno foi positivo (valor entre 0 e 1). Indica com que frequência a ação deu lucro no mês.

Como a igualdade de variâncias entre as ações já foi verificada na Seção 5.1.2 (Fligner-Killeen), a variabilidade por si só não separa V1 de V3; o desempate se apoia, portanto, na **dominância** de V1 no conjunto de indicadores: maior média (1,34% contra 0,83%), menor desvio-padrão (0,93% contra 0,97%), maior razão retorno/risco (1,45 contra 0,86), pior mês menos severo (-0,27% contra -0,81%) e mais meses positivos (91% contra 83%). V1 é melhor ou igual a V3 em todos os critérios: rende mais em média e não exige assumir mais risco para isso. Esse conjunto constitui a evidência para a escolha de uma única ação, conforme pede a segunda pergunta do experimento.

6 Conclusões e Recomendações

1. **Teste global:** o ANOVA rejeitou H_0 ($p = 1,32 \times 10^{-4}$). As cinco ações não têm o mesmo retorno médio mensal.

Teste	Nº de comparações	FWER sem correção	FWER com correção
Tukey (todos contra todos)	10	40,1%	5%
Dunnett (todos contra V1)	4	18,5%	5%

Tabela 5: Probabilidade de ao menos um falso positivo (erro family-wise) com e sem a correção para comparações múltiplas.

2. **Ações que se destacam:** o teste de Dunnett, tomando V1 como referência, descartou V2, V4 e V5 ($p < 0,05$). Restaram **V1 e V3**, sem diferença significativa entre si.
3. **Desempate:** como não é válido aplicar um novo teste de hipóteses entre as duas, a escolha foi feita por análise de risco e variabilidade. V1 domina V3 em todos os indicadores: maior retorno médio, menor desvio-padrão, maior razão retorno/risco, pior mês menos severo e mais meses positivos.
4. **Recomendação:** investir na ação **V1**, com retorno médio estimado de 1,34% ao mês. V3 é a alternativa estatisticamente indistinguível em retorno médio, mas com mais risco e menor razão retorno/risco. Vale lembrar que o retorno médio histórico não garante o retorno do próximo mês, pois a variabilidade mensal (cerca de 1 p.p.) é grande em relação às diferenças entre as médias.

7 Discussão da significância e dos riscos do teste

Todo teste de hipóteses pode errar de duas formas: rejeitar H_0 quando ela é verdadeira (**erro tipo I**, cuja probabilidade máxima é o nível de significância α) e não rejeitar H_0 quando ela é falsa (**erro tipo II**, de probabilidade β). A potência do teste, $1 - \beta$, é a probabilidade de detectar uma diferença que de fato existe. Nesta seção discute-se como esses dois riscos se distribuem ao longo do procedimento adotado e o que eles significam para a decisão do investidor.

7.1 Nível de significância e controle do erro tipo I

Adotou-se $\alpha = 0,05$ em todos os testes. Para o investidor, um erro tipo I significa apontar uma ação como diferente das demais quando, na verdade, todas têm o mesmo retorno médio: a análise “enxergaria” uma vencedora que não existe.

Esse risco é controlado de forma diferente em cada etapa. No ANOVA, o α se refere a uma única hipótese global. Nas comparações múltiplas, porém, cada comparação adicional é uma nova oportunidade de erro: se as m comparações fossem feitas com testes t independentes, cada um a 5%, a probabilidade de ao menos um falso positivo no conjunto (erro *family-wise*, FWER) seria $1 - (1 - \alpha)^m$. A Tabela 5 mostra esse valor para as duas famílias usadas no relatório.

É aí que entra o controle *family-wise*: os p -valores reportados nas Seções 5.3 e 5.4 já são **ajustados** (método *single-step* do pacote `multcomp`, que usa a distribuição conjunta dos contrastes), de modo que a probabilidade de qualquer falso positivo dentro de cada família fica em 5%. O preço dessa proteção é um teste mais conservador: cada comparação individual precisa de uma diferença maior para ser declarada significativa. Como o Dunnett tem menos comparações na família (4 contra 10 do Tukey), ele paga uma correção menor e por isso consegue separar V5 de V1 ($p = 0,0326$) onde o Tukey não conseguiu ($p = 0,0697$).

7.2 Por que não se usou um teste t para o desempate

Seria tentador decidir entre V1 e V3 com um teste t direto, **sem correção**, feito **depois** de examinar os resultados anteriores. Isso tem duas consequências. Primeiro, o seu α nominal de 5% não seria mais exato: a comparação teria sido escolhida justamente por ser a mais promissora entre as que restaram, o que favorece a rejeição. Segundo, o resultado dependeria de quanto se cobra pela multiplicidade: a Tabela 6 mostra a mesma diferença $\mu_1 - \mu_3$ avaliada pelos três procedimentos.

A diferença observada (0,51 p.p. ao mês) é a mesma nos três casos; o que muda é o quanto de proteção contra o erro tipo I se exige. Só o procedimento que não paga pela multiplicidade rejeita, o que é sinal de evidência **marginal**, não de evidência forte. Por isso o relatório não usa o teste t como decisão: o teste confirmatório

Procedimento	p-valor (V1 vs V3)	Decisão a 5%
Tukey (família de 10 comparações)	0,2233	não rejeita
Dunnett (família de 4 comparações)	0,1176	não rejeita
Teste t de Student sem correção (não adotado)	0,0290	rejeita

Tabela 6: A comparação V1 vs V3 sob os três procedimentos: a conclusão muda conforme a correção aplicada.

Quantidade	Valor
Potência do ANOVA (5 grupos, $n = 35$)	99%
Potência do teste t V1 vs V3 para a diferença observada	59%
Menor diferença detectável com 80% de potência ($n = 35$)	0,64 p.p. ao mês
n por ação para 80% de potência na diferença observada	57 meses
n por ação para 90% de potência na diferença observada	75 meses

Tabela 7: Potência dos testes ao nível de significância de 0,05. Diferença observada V1 vs V3 = 0,51 p.p.; desvio-padrão combinado = 0,95 p.p.

é o Dunnett, e a escolha entre V1 e V3 é feita pelo critério de risco e variabilidade da Seção 5.6, que não depende de um novo teste sobre as mesmas médias.

7.3 Erro tipo II e potência dos testes

O risco oposto, o erro tipo II, é o mais relevante para a comparação V1 vs V3: é possível que V1 seja de fato melhor e o experimento simplesmente não tenha dados suficientes para mostrar isso com segurança. Como o tamanho amostral foi definido pela janela fixa de 36 meses de dados disponível, não houve escolha de tamanho amostral; o que se pode fazer é avaliar que diferenças essa amostra é capaz de detectar.

A Tabela 7 resume os cálculos (função `power.t.test`, teste bilateral com variâncias iguais, usando o desvio-padrão combinado de V1 e V3). O teste global tem potência de 99%: com 5 ações e 35 meses, o ANOVA quase certamente detectaria a dispersão de médias observada, o que é coerente com a rejeição clara de H_0 . Já para separar V1 de V3, a situação é outra. A diferença observada, de 0,51 p.p. ao mês, corresponde a um efeito de tamanho moderado ($d = \delta/s \approx 0,53$), e a potência para detectá-lo com 35 meses por ação é de apenas **59%**: mesmo que V1 seja realmente melhor por essa margem, haveria cerca de 41% de chance de o teste não a distinguir de V3. Com essa amostra, só diferenças a partir de 0,64 p.p. ao mês seriam detectadas com 80% de potência. Para ter 80% de potência na diferença observada seriam necessários cerca de 57 meses de histórico por ação (cerca de 4,8 anos), e 75 meses para 90%.

Vale a ressalva de que essa potência é calculada *a posteriori*, com a diferença observada no lugar do efeito verdadeiro, e por isso é apenas uma referência (ela é função direta do p-valor obtido). O resultado útil é a menor diferença detectável e o tamanho de amostra necessário, que descrevem a sensibilidade do experimento independentemente do que se observou. A Figura 7 ilustra as duas leituras.

Em resumo, 36 meses de dados bastam para separar V1 de V2, V4 e V5, cujas diferenças em relação a V1 são maiores, mas não para separar V1 de V3 com segurança. A incerteza que resta nessa comparação não é falha da análise: é o limite de potência imposto pelo tamanho da amostra disponível.

7.4 O que os dois riscos significam para o investidor

Os dois tipos de erro têm custos muito diferentes neste problema, e isso ajuda a interpretar os resultados. Se o investidor escolher V1 e, na verdade, V1 e V3 tiverem o mesmo retorno médio (o equivalente a um erro tipo I na comparação final), o custo esperado é nulo: ele investiu em uma ação tão boa quanto a alternativa. Se, por outro lado, V1 for de fato superior e o investidor tratar as duas como equivalentes (erro tipo II), ele abre mão, em média, de cerca de 0,51 p.p. ao mês. Como o investidor precisa, de qualquer forma, escolher **uma** ação, a decisão de ficar com a de maior média amostral, V1, é a que minimiza o arrependimento esperado, e é essa a recomendação da Seção 6. A rigidez do $\alpha = 5\%$ nas comparações múltiplas protege contra falsos




Figura 7: Potência do teste t (V1 vs V3, $\alpha = 0,05$). À esquerda, potência em função do número de meses por ação, para a diferença observada; à direita, potência em função da diferença entre as médias, para $n = 35$. Os pontos marcam a situação do experimento.

positivos, o que é importante para a conclusão científica, mas, para este investidor em particular, o erro mais caro é o tipo II, e por isso a evidência marginal a favor de V1 ainda deve orientar a escolha.

Por fim, é importante distinguir a incerteza sobre a **média** da incerteza sobre o **próximo mês**. Os testes tratam da média de longo prazo. A variabilidade mensal dos retornos (desvio-padrão de cerca de 0,95 p.p.) é quase o dobro da diferença entre as médias de V1 e V3, e nos 35 meses observados V1 rendeu mais que V3 em apenas 63% dos meses. Mesmo que V1 seja a melhor escolha em média, há uma chance considerável de V3 render mais em um mês específico. Nenhum teste de hipóteses elimina esse risco, que é inerente à decisão de investir em uma única ação.

8 Possíveis melhorias do experimento

- Ampliar a janela histórica (mais de 36 meses) e/ou usar retornos semanais, aumentando o número de observações e a potência.
- Considerar dividendos, custos de transação e impostos.
- Ajustar o retorno ao risco (índice de Sharpe, com taxa livre de risco) em vez de comparar só médias.
- Usar bootstrap ou testes de permutação para intervalos e comparações sem hipótese distribucional.
- Avaliar o desempenho fora da amostra (janela deslizante), já que rentabilidade passada não garante a do mês seguinte.
- Incluir mais ações e considerar diversificação (carteira) em vez de uma única ação.
- Definir antes do experimento a margem de equivalência economicamente relevante, para usar testes de equivalência/não inferioridade em vez de depender de p -valores marginais.

9 Papéis desempenhados pela equipe

Integrante	Papel
Adonai Arruda	Relator: estruturação e redação do relatório em R Markdown a partir do script de análise, integração das contribuições da equipe e revisão final.

Integrante	Papel
Alexandra Milaya Soto Aponte	Programadora/Analista: desenvolvimento do arquivo <code>exploracao_dos_dados.R</code> , abrangendo o pré-processamento, a análise exploratória e a aplicação de testes estatísticos: normalidade, homocedasticidade e testes de comparações múltiplas (Tukey, Dunnett e t de Student), com comentários sobre a motivação de cada teste e a interpretação dos resultados.
João Paulo Gonçalves Simim	Analista: discussão da significância, dos riscos de erro tipo I e II e da potência dos testes (Seção 7); verificação da compilação do relatório em PDF.
Yasmim Machado	Verificador: compilação independente do relatório, revisão dos resultados, redação do relatório, e das sugestões de melhoria.

10 Declaração sobre o uso de IA generativa

Durante a preparação deste trabalho, os autores utilizaram o Claude (Anthropic) para redigir a versão inicial das seções descritivas deste relatório, a partir dos resultados registrados como comentários no script de análise `exploracao_dos_dados.R`. Após utilizar essa ferramenta, os autores revisaram, editaram e finalizaram o conteúdo conforme necessário e assumem total responsabilidade pelo conteúdo da publicação.

A ferramenta também foi utilizada na revisão metodológica da análise. Nessa revisão, ela ajudou os autores a identificar que a sequência de testes inicialmente adotada (Tukey, seguido de Dunnett e de um teste t sem correção sobre as duas ações restantes) não controlava adequadamente o erro tipo I, e corrigiu a interpretação de que V1 seria estatisticamente superior a V3. Com base nisso, os autores reestruturaram a análise, adotando o teste de Dunnett como único teste confirmatório e a análise de risco e variabilidade como critério de desempate, e redigiram, com apoio da ferramenta, a Seção 7 (significância, riscos e potência dos testes) e a verificação da premissa de independência. Todos os cálculos e conclusões foram conferidos pelos autores.

Também foi utilizada IA para auxiliar na formatação do texto, incluindo a inclusão de bibliotecas que ajudam na visualização de gráficos e tabelas apresentados no relatório. Da mesma forma, foi solicitado apoio para revisar o chunk de setup do R Markdown, de modo a garantir a instalação das bibliotecas necessárias para que o arquivo compilasse sem erros.

11 Referências

- MONTGOMERY, D. C. *Design and Analysis of Experiments*. 9. ed. John Wiley & Sons, 2017.
- TUKEY, J. W. Comparing individual means in the analysis of variance. *Biometrics*, v. 5, n. 2, p. 99–114, 1949.
- DUNNETT, C. W. A multiple comparison procedure for comparing several treatments with a control. *Journal of the American Statistical Association*, v. 50, n. 272, p. 1096–1121, 1955.
- R CORE TEAM. *R: A language and environment for statistical computing*. R Foundation for Statistical Computing, Vienna, Austria, 2025. Pacotes `multcomp` (comparações múltiplas) e `car` (diagnósticos).
- BESSANI, M. Material da disciplina EEE933 - Planejamento e Análise de Experimentos (notas de aula sobre ANOVA e comparações múltiplas). PPGE/UFMG, 2026.