Estudo de Caso 03: Comparação de desempenho de duas configurações de um algoritmo de otimização

EEE933 - Planejamento e Análise de Experimentos — PPGEE/UFMG

Adonai Arruda, Alexandra Milaya Soto Aponte, João Paulo Gonçalves Simim, Yasmim Machado

05 de outubro de 2026

1 Resumo

2 Introdução

Algoritmos baseados em populações são frequentemente utilizados em problemas de otimização em engenharia. Neles, um conjunto de soluções candidatas é submetido iterativamente a operadores de variação e seleção, explorando o espaço de busca em direção ao mínimo (ou máximo) de uma função objetivo.

Entre esses algoritmos, destaca-se o método de **evolução diferencial** (DE, do inglês *Differential Evolution*), proposta por Storn e Price (1997), cujo funcionamento pode ser resumido assim:

Entrada: N (tamanho da população), n_{iter} (número de iterações), recpars e mutpars (parâmetros de recombinação e mutação).

1. **Inicialização:** $t \leftarrow 0$; gerar a população inicial $X_t = \{\vec{x}_1, \ldots, \vec{x}_N\}$ e avaliar $\vec{f}_t \leftarrow f(X_t)$.
2. **Enquanto** $t < n_{\text{iter}}$:
    1. **Mutação:** $V_t \leftarrow \text{mutação}(X_t, \text{mutpars})$
    2. **Recombinação:** $U_t \leftarrow \text{recombinação}(X_t, V_t, \text{recpars})$
    3. **Avaliação:** $\vec{j}_t \leftarrow f(U_t)$
    4. **Seleção:** $(X_{t+1}, \vec{f}_{t+1}) \leftarrow \text{seleção}(X_t, U_t, \vec{f}_t, \vec{j}_t)$
    5. $t \leftarrow t + 1$
3. **Saída:** população final e valores da função objetivo, $(X_t, \vec{f}_t)$.

Neste estudo, o critério de parada é um número máximo de avaliações da função objetivo ($5000 \cdot \dim$), e o desempenho de cada execução é medido pelo melhor valor encontrado (`Fbest`). Valores menores indicam melhor desempenho.

O objetivo é comparar duas configurações do DE na classe de problemas formada pelas funções de Rosenbrock com dimensão entre 2 e 150. Cada configuração combina um operador de recombinação e um de mutação. Neste caso de estudo particular, ambas configurações usam a mutação `mutation_rand`, mas com fatores de escala F diferentes:

- **Configuração 1:** recombinação por linha (*line recombination*) do *Breeder Genetic Algorithm* (BGA), `recombination_lbga`; mutação *rand* com $F = 4{,}5$.
- **Configuração 2:** *Blend Crossover* Alpha-Beta (BLX-$\alpha\beta$), `recombination_blxAlphaBeta`, com $\alpha = 0{,}1$ e $\beta = 0{,}4$; mutação *rand* com $F = 3$.

3 Planejamento do Experimento

3.1 Objetivo e hipóteses

O objetivo deste experimento é responder a três perguntas:

1. Existe diferença no desempenho médio das duas configurações na classe de problemas considerada?
2. Se existir, qual configuração é melhor e qual a magnitude da diferença?
3. Os resultados justificam recomendar uma configuração em relação à outra?

Seja Y_{ij} o desempenho médio da configuração i na instância j, correspondente a uma função de Rosenbrock de dimensão específica. Para comparar as duas configurações em uma mesma instância, define-se a diferença pareada de desempenho como:

$$\psi_j = \bar{Y}_{2j} - \bar{Y}_{1j}$$

Como o desempenho é avaliado pelo valor de `Fbest`, que deve ser minimizado, valores de $\psi_j > 0$ indicam que a configuração 1 apresentou melhor desempenho, enquanto valores de $\psi_j < 0$ favorecem a configuração 2.

Assim, define-se $\mu_D = E[\psi_j]$ como a diferença média esperada de desempenho entre as duas configurações, considerando o conjunto de instâncias avaliadas. Desta forma, as hipóteses a serem testadas a fim de responder às perguntas do experimento são:

$$\begin{cases} H_0 : \mu_D = 0 \\ H_1 : \mu_D \neq 0 \end{cases}$$

Onde, H_0 estabelece que não há diferença média de desempenho entre as duas configurações, enquanto H_1 admite diferença em qualquer direção. Já, o sinal da estimativa de μ_D e seu intervalo de confiança indicarão qual configuração é melhor, caso H_0 seja rejeitada.

3.2 Coleta dos dados e Tamanho amostral

O planejamento do experimento exige a definição de dois tamanhos amostrais, seguindo a metodologia de Campelo e Takahashi (2019):

1. o número de instâncias, N, suficiente para detectar a diferença de interesse e representativo da classe de problemas, isto é, funções de Rosenbrock com dimensão entre 2 e 150;
2. o número de repetições de cada configuração em cada instância, n_{ij}, que permita estimar com precisão adequada o desempenho médio da configuração i na instância j.

3.2.1 Número de instâncias (N)

O enunciado do estudo de caso (referência) estabelece os seguintes parâmetros experimentais:

- Mínima diferença de importância prática (padronizada): $d^* = \delta^*/\sigma = 0{,}5$
- Nível de significância: $\alpha = 0{,}05$
- Potência mínima (para $d = d^*$): $\pi = 1 - \beta = 0{,}8$

Com base nesses valores, realizou-se uma análise de potência para o teste t pareado bilateral, a fim de determinar o menor número de instâncias capaz de detectar uma diferença de importância prática com o nível de significância e a potência especificados. Como d^* já é uma quantidade padronizada, utilizaram-se `delta = 0.5` e `sd = 1`.

```
##
##      Paired t test power calculation
##
##               n = 33.3672
```

```
##           delta = 0.5
##              sd = 1
##       sig.level = 0.05
##           power = 0.8
##     alternative = two.sided
##
## NOTE: n is number of *pairs*, sd is std.dev. of *differences* within pairs
```

O resultado foi $n = 33{,}4$, que, arredondado para cima, corresponde a $N^* = 34$ instâncias. As duas configurações são avaliadas nas mesmas instâncias, o que garante o pareamento dos dados.

Para que as instâncias constituam uma amostra representativa da classe de problemas, as $N^* = 34$ dimensões foram sorteadas aleatoriamente, sem reposição, entre os inteiros de 2 a 150, com semente fixa para garantir a reprodutibilidade. As instâncias avaliadas são apresentadas a seguir:

Dimensões selecionadas: 4, 9, 13, 32, 35, 36, 39, 43, 45, 46, 49, 57, 59, 62, 67, 80, 89, 92, 94, 99, 100, 101, 102, 109, 111, 112, 114, 115, 122, 127, 131, 132, 134, 148 .

3.2.2 Número de repetições (n_{ij})

Para determinar o número de repetições de cada configuração em cada instância, implementou-se o Algoritmo 1 de Campelo e Takahashi (2019). Em cada instância, o algoritmo executa inicialmente n_0 repetições de cada configuração e, em seguida, acrescenta uma repetição por vez até que o erro padrão da diferença de desempenho ψ_j atinja a precisão desejada, ou até que um orçamento máximo de execuções, n_{max}, seja alcançado. As repetições adicionais são alocadas preferencialmente à configuração de maior variância, de modo que n_{1j} e n_{2j} podem ser diferentes.

Quanto a n_0, os autores recomendam basear a escolha na forma da distribuição do desempenho do algoritmo: valores baixos (3 ou 4) para distribuições aproximadamente gaussianas, em torno de 10 para outras distribuições simétricas e 20 ou 30 para distribuições fortemente assimétricas. Adotou-se $n_0 = 20$, valor que atende bem à maioria dos casos. Nas instâncias em que a variabilidade é maior, o algoritmo acrescenta repetições até alcançar a precisão desejada. O orçamento máximo foi fixado em $n_{max} = 200$ execuções por instância, somando as duas configurações.

4 Análise exploratória e tratamento dos dados

As inferências deste experimento são realizadas sobre ψ_j, a diferença de desempenho médio entre as configurações na instância j. Por isso, os dados brutos obtidos das execuções do algoritmo passaram por duas etapas de processamento:

1. para cada dimensão (instância), calculou-se o desempenho médio de cada configuração, $\bar{F}_{1j}$ e $\bar{F}_{2j}$, a partir das n_{1j} e n_{2j} repetições do melhor valor encontrado (`Fbest`);
2. a partir dessas médias, calculou-se a diferença $\psi_j^{\text{bruto}} = \bar{F}_{2j} - \bar{F}_{1j}$, observação amostral da diferença de desempenho na instância j, na escala original.

A Figura 1 apresenta as diferenças entre as médias de desempenho das configurações em cada instância avaliada. Observa-se que as diferenças são maiores nas instâncias de maior dimensão. Isso não deve ser interpretado, por si só, como uma diferença maior entre as configurações, pois a ordem de grandeza dos valores da função de Rosenbrock cresce com a dimensão d (Pohlheim, 2005). Assim, diferenças absolutas tendem a crescer com d mesmo que a diferença relativa entre as configurações seja a mesma. Esse comportamento pode ser constatado na Tabela 2, apresentada no Apêndice. A diferença de escala entre as instâncias motivou a verificação da normalidade das diferenças e a avaliação de uma transformação dos dados, descritas nas próximas seções.

Para compreender melhor o comportamento dos dados, selecionou-se uma subamostra de 9 das 34 instâncias, distribuídas ao longo do intervalo de dimensões para representar instâncias de baixa, média e alta dimensão.

Dimensões selecionadas para a análise exploratória: 4, 9, 32, 49, 62, 92, 94, 102, 122 .

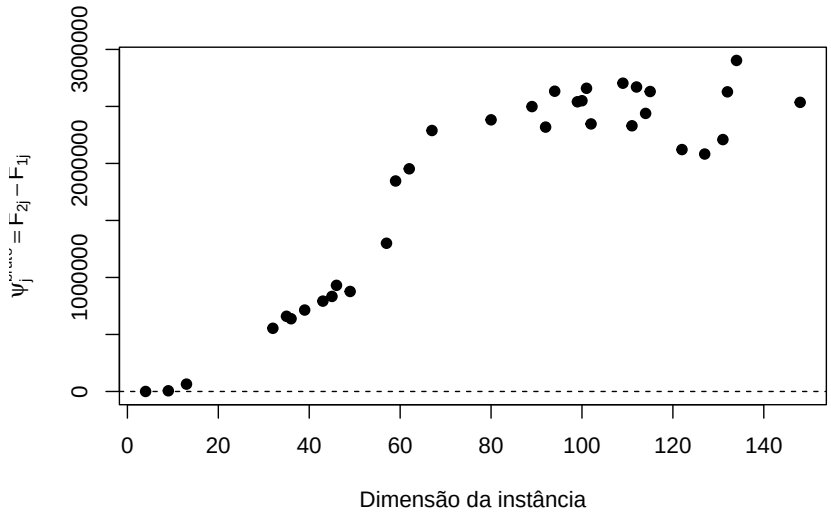


Figura 1: Diferença de desempenho médio entre as configurações em cada instância, em função da dimensão (escala original).

A Figura 2 mostra os dados brutos de desempenho de ambas as configurações. Em linhas gerais, os dados indicam que:

- em todas as instâncias do subconjunto, a configuração 1 apresenta melhor desempenho, isto é, valores de `Fbest` menores;
- nas instâncias de menor dimensão o algoritmo alcança valores menores do que nas de maior dimensão, o que indica que é conveniente tratar os dados para colocar as instâncias em uma escala comparável.

4.0.1 Normalidade das diferenças na escala original

O teste de Shapiro-Wilk rejeita a normalidade das diferenças ψ_j^{bruto} ($p = 0.000223$). O gráfico quantil-quantil (Figura 3) mostra uma curva em forma de S, com um patamar em torno de 2,5 milhões, coerente com o efeito da escala descrito anteriormente.

4.0.2 Transformação logarítmica

Como a ordem de grandeza de `Fbest` varia fortemente com a dimensão, as diferenças foram calculadas sobre o logaritmo natural do desempenho. Define-se

$$\bar{Y}_{ij} = \frac{1}{n_{ij}} \sum_{k=1}^{n_{ij}} \log(F_{best,ijk}), \qquad \psi_j = \bar{Y}_{2j} - \bar{Y}_{1j},$$

em que $F_{best,ijk}$ é o valor obtido na repetição k da configuração i na instância j.

Após a transformação, o teste de Shapiro-Wilk ainda rejeita a normalidade ($p = 2.66e-08$). No entanto, como mostra a Figura 4, a maior parte dos pontos acompanha a reta do gráfico quantil-quantil, e o desvio é provocado principalmente por três instâncias, de dimensões 1,2 e 3, instâncias onde a diferença era próxima a zero.

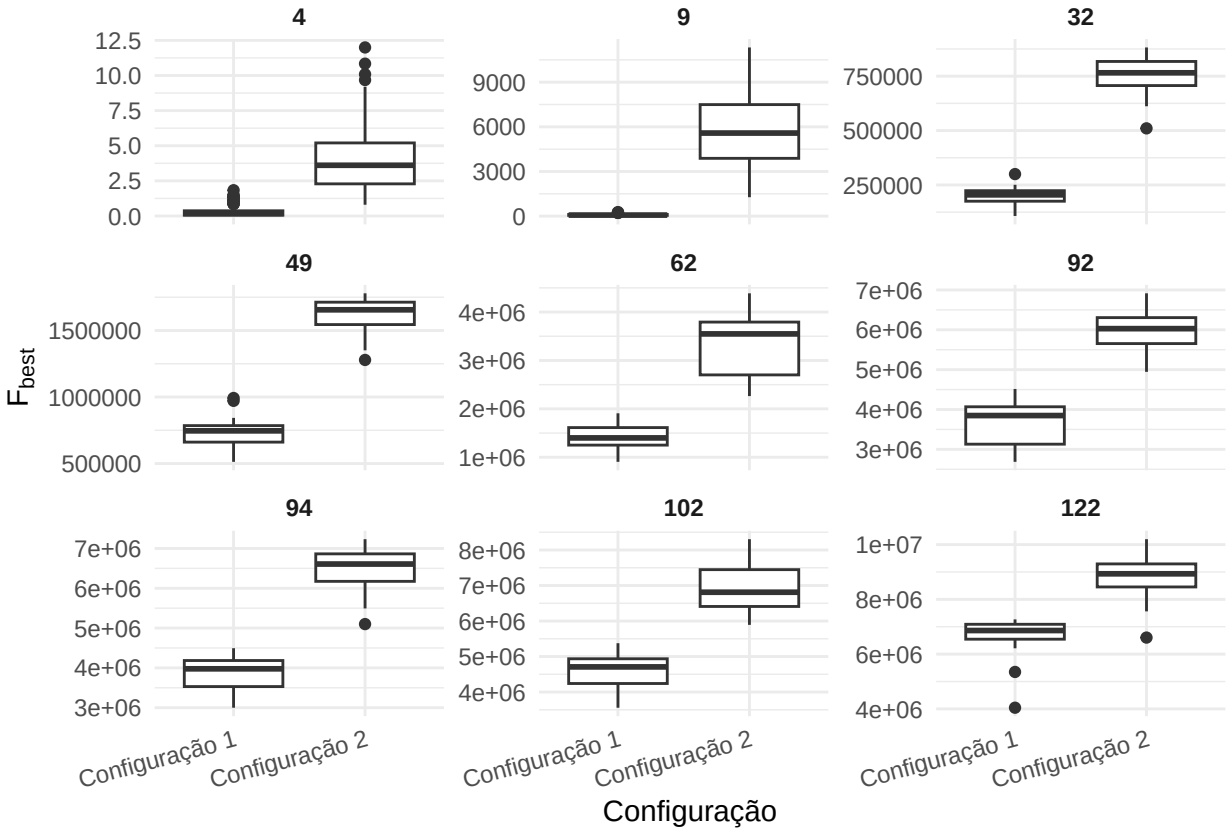


Figura 2: Distribuição do desempenho (Fbest) de cada configuração nas instâncias do subconjunto exploratório.

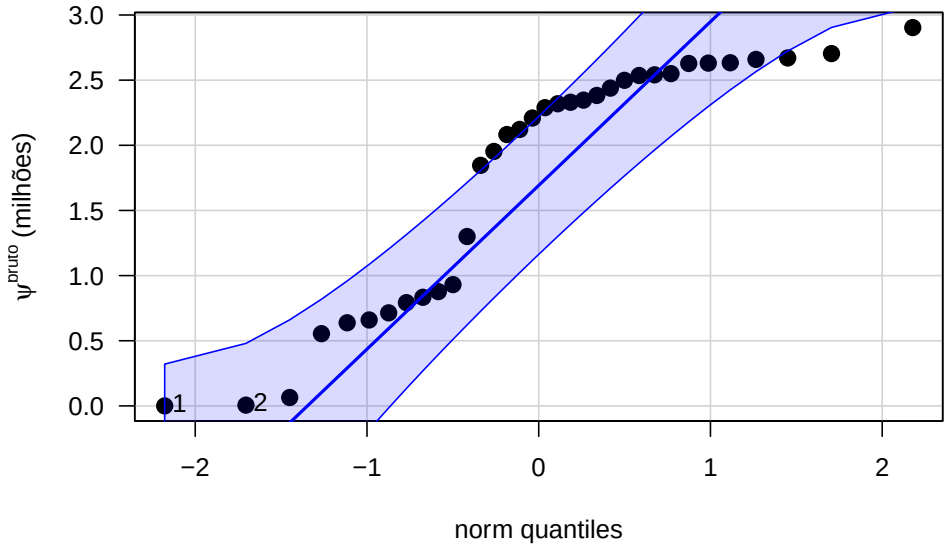


Figura 3: Gráfico quantil-quantil das diferenças de desempenho na escala original.

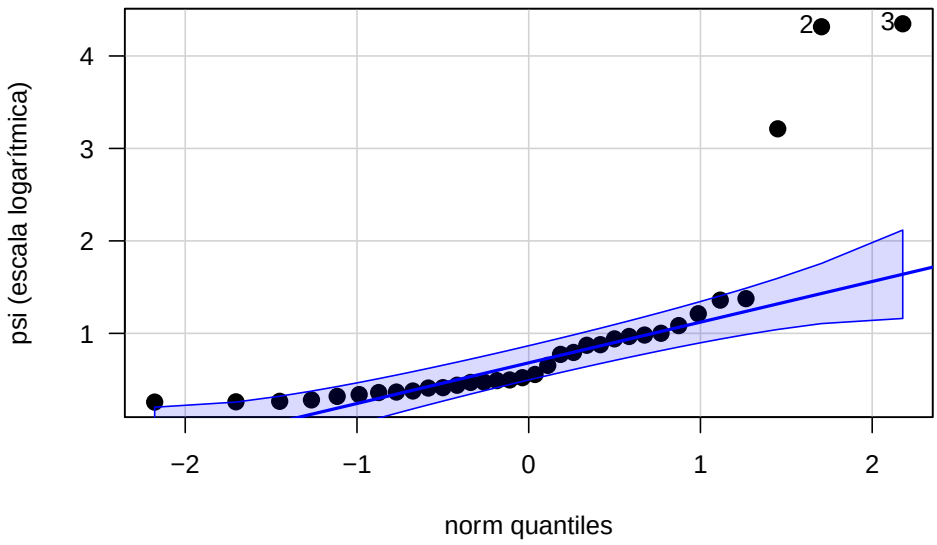


Figura 4: Gráfico quantil-quantil das diferenças de desempenho na escala logarítmica.

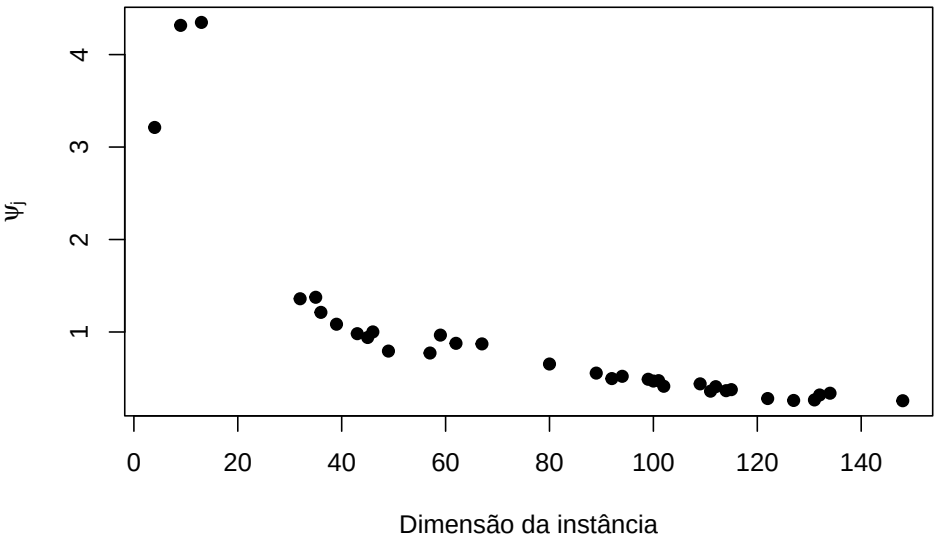


Figura 5: Diferença de desempenho na escala logarítmica, em função da dimensão.

5 Análise Estatística

A análise usa as 34 diferenças ψ_j na escala logarítmica (Seção 4), uma por instância, com $\alpha = 0{,}05$. As repetições servem apenas para estimar cada ψ_j; tratá-las como observações independentes seria pseudorreplicação (Campelo e Takahashi, 2019).

5.1 Teste de hipóteses

As hipóteses definidas na Seção 2 são:

- **Hipótese nula** ($H_0 : \mu_D = 0$): as duas configurações têm o mesmo desempenho médio;
- **Hipótese alternativa** ($H_1 : \mu_D \neq 0$): as duas configurações têm desempenho médio diferente.

Para testá-las, usou-se o teste t pareado bilateral, que equivale a um teste t de uma amostra sobre as diferenças ψ_j. A estatística do teste é a média das diferenças dividida pelo seu erro padrão, $t_0 = \bar{\psi}/(s_\psi/\sqrt{N})$, em que $\bar{\psi} = 0{,}937$ é a média e $s_\psi = 1{,}020$ é o desvio padrão das 34 diferenças. Com esses valores, $t_0 = 0{,}937/(1{,}020/\sqrt{34}) = 5{,}36$, com $N - 1 = 33$ graus de liberdade.

O p-valor é a chance de observar uma diferença média tão grande quanto essa se H_0 fosse verdadeira. Aqui, $p < 0{,}001$, bem abaixo de $\alpha = 0{,}05$.

Resultado: rejeita-se H_0 em favor de H_1, ou seja, há diferença no desempenho médio das duas configurações. Como $\bar{\psi} > 0$, a configuração 2 tem, em média, maior $\log(F_{best})$, e portanto a configuração 1 é a melhor. Ela obteve menor média de $\log(F_{best})$ em todas as 34 instâncias (Figura 5).

5.2 Verificação das premissas

O teste t pareado supõe independência entre os ψ_j e normalidade da distribuição amostral de $\bar{\psi}$.

- **Independência:** garantida pelo planejamento. As dimensões foram sorteadas sem reposição e cada instância contribui com um único ψ_j.
- **Normalidade:** o teste de Shapiro-Wilk rejeita a normalidade dos ψ_j ($p < 0{,}001$, Seção 4). Como a premissa se refere à média, a distribuição amostral de $\bar{\psi}$ foi estimada por *bootstrap* (Campelo e Takahashi, 2019): os 34 valores de ψ_j foram reamostrados com reposição 9999 vezes, calculando-se a média de cada reamostra. No gráfico quantil-quantil dessas médias (Figura 6), os pontos acompanham a reta no centro, mas se curvam para cima nas duas extremidades. Isso indica assimetria à direita, causada pelas três instâncias atípicas da Seção 4. Logo, o p-valor e o intervalo de confiança do teste t são aproximados.

Para confirmar a conclusão sem depender da normalidade, aplicou-se o teste do sinal, que exige apenas independência. O teste conta em quantas instâncias a configuração 1 foi melhor ($\psi_j > 0$): foram 34 de 34. Se H_0 fosse verdadeira, cada instância teria 50% de chance de favorecer cada configuração, como no lançamento de uma moeda. A chance de todas as 34 favorecerem a mesma configuração seria de $2 \times 0{,}5^{34}$, em que o fator 2 conta os dois casos possíveis (todas a favor da configuração 1 ou todas a favor da configuração 2). Esse valor é o p-valor do teste, e $p < 0{,}001$. Portanto, o teste do sinal também rejeita H_0.

5.3 Magnitude da diferença

A diferença média estimada, na escala logarítmica, é $\hat{\mu}_D = 0{,}94$. O IC 95% do teste t é calculado por $\bar{\psi} \pm t_{0{,}975;\,33} \cdot s_\psi/\sqrt{N}$, em que $t_{0{,}975;\,33} = 2{,}035$ é o valor crítico da distribuição t. Com os dados, $0{,}937 \pm 2{,}035 \times 1{,}020/\sqrt{34}$, o intervalo vai de 0,58 a 1,29. Pelo *bootstrap* percentil, que não supõe normalidade, o IC 95% vai do percentil 2,5% ao 97,5% das 9999 médias bootstrap, de 0,63 a 1,31. Os dois intervalos contêm apenas valores positivos, isto é, favorecem a configuração 1.

O efeito padronizado é a média dividida pelo desvio padrão das diferenças: $\hat{d} = 0{,}937/1{,}020 = 0{,}92$. Esse valor é maior que a mínima diferença de importância prática, $d^* = 0{,}5$, e portanto a diferença também é relevante na prática.

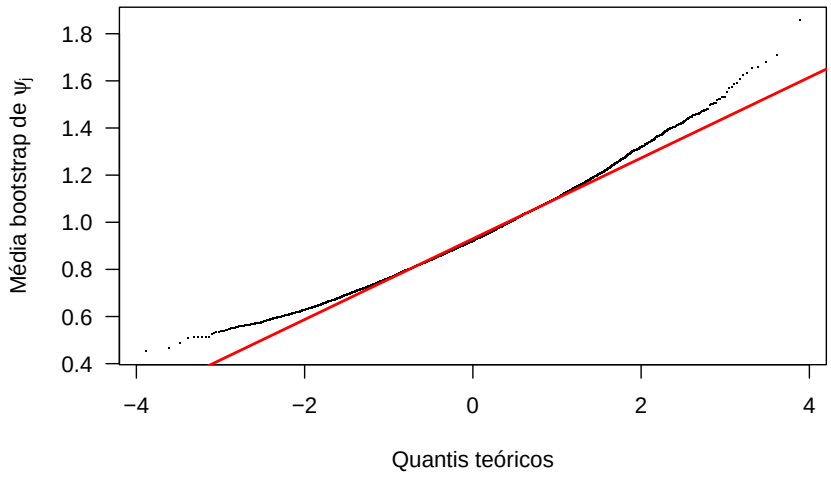


Figura 6: Gráfico quantil-quantil das médias bootstrap das diferenças ψ_j (9999 reamostragens).

Por fim, para entender a magnitude na escala original do `Fbest`, aplica-se a exponencial, que é o inverso do logaritmo. Como ψ_j é uma diferença de logaritmos, a exponencial de $\bar{\psi}$ é uma razão entre os desempenhos: $e^{0{,}937} = 2{,}55$. Ou seja, em média (geométrica), o `Fbest` da configuração 2 é 2,55 vezes o da configuração 1. Dito de outra forma, a configuração 1 obtém um `Fbest` cerca de 61% menor. Aplicando a exponencial aos limites do IC 95% do teste t, a razão fica entre 1,79 e 3,64, o que corresponde a um `Fbest` de 44% a 73% menor com a configuração 1.

6 Conclusões e Recomendações

7 Discussão da significância e dos riscos do teste

7.1 Nível de significância e controle do erro tipo I

7.2 Erro tipo II e potência dos testes

8 Possíveis melhorias do experimento

- A exploração dos dados com um piloto antes da execução das 34 instâncias poderia ter otimizado os recursos computacionais ao fixar um n_0 mais conveniente para o conjunto de instâncias.

9 Papéis desempenhados pela equipe

Integrante	Papel
Adonai Arruda	Relator:
Alexandra Milaya Soto Aponte	Relatora/ Analista: Responsável pela programação e redação da Introdução e das seções de Planejamento do Experimento e Análise Exploratória dos Dados.
João Paulo Gonçalves Simim	Analista:

Integrante	Papel
Yasmim Machado	Verificador:

10 Declaração sobre o uso de IA generativa

Durante a preparação deste trabalho, os autores utilizaram o Claude (Anthropic) para:

- Implementar em R o pseudocódigo do Algoritmo 1 desenvolvido por Campelo e Takahashi (2019) para determinar o número de repetições n_{ij} até que o erro padrão da diferença de desempenho ψ_j atinja a precisão desejada.
- Formatação de gráficos e tabelas

11 Referências

- BESSANI, M. Material da disciplina EEE933 - Planejamento e Análise de Experimentos (notas de aula sobre ANOVA e comparações múltiplas). PPGEE/UFMG, 2026.

12 Apêndice: desempenho médio por instância

Dimensão	Média Config. 1	n1	Média Config. 2	n2	Diferença (psi bruto)
4	0.29	136	4.20	64	3.91
9	85.78	99	5949.01	75	5863.23
13	922.54	80	65316.87	54	64394.32
32	196419.13	20	750629.88	20	554210.75
35	237681.42	20	897031.14	20	659349.72
36	276990.44	20	914858.07	20	637867.63
39	370933.98	20	1085031.32	20	714097.34
43	500132.07	20	1292477.69	20	792345.62
45	555662.32	20	1389235.94	20	833573.63
46	556527.02	20	1487268.97	20	930741.94
49	736880.89	20	1613800.40	20	876919.51
57	1146780.69	20	2446673.39	20	1299892.70
59	1140902.48	20	2986936.01	20	1846033.52
62	1390624.72	20	3343388.07	20	1952763.35
67	1677880.71	20	3966622.34	20	2288741.63
80	2658236.29	20	5040589.99	20	2382353.70
89	3382518.55	20	5881098.24	20	2498579.69
92	3695349.74	20	6014122.68	20	2318772.94
94	3871183.78	20	6504508.42	20	2633324.64
99	4133132.88	20	6673817.15	20	2540684.27
100	4303422.73	20	6853335.75	20	2549913.02
101	4462125.51	20	7121242.93	20	2659117.43
102	4599981.35	20	6946558.42	20	2346577.06
109	4928367.35	20	7632129.88	20	2703762.53
111	5433973.70	20	7764172.98	20	2330199.29
112	5370913.09	20	8041262.86	20	2670349.77
114	5675793.99	20	8114445.98	20	2438652.00
115	5795081.30	20	8425711.51	20	2630630.21
122	6653460.52	20	8775081.97	20	2121621.45
127	7046260.34	20	9128671.14	20	2082410.81
131	7334573.90	20	9543824.79	20	2209250.89
132	7142759.32	20	9770546.04	20	2627786.72
134	7337425.27	20	10240711.48	20	2903286.21
148	8765676.62	20	11301341.95	20	2535665.33

Tabela 2: Desempenho médio (escala original) e número de repetições por instância.