Estudo de Caso 03: Comparação de desempenho de duas configurações de um algoritmo de otimização

EEE933 - Planejamento e Análise de Experimentos — PPGEE/UFMG

Adonai Arruda, Alexandra Milaya Soto Aponte, João Paulo Gonçalves Simim, Yasmim Machado

02 de novembro de 2026

Resumo

Este estudo compara duas configurações do algoritmo de evolução diferencial na classe de funções de Rosenbrock com dimensão entre 2 e 150. Sortearam-se 34 instâncias, número definido para potência de 0,8 na detecção de uma diferença padronizada $d^* = 0{,}5$ com $\alpha = 0{,}05$. Em cada instância, cada configuração foi executada ao menos 20 vezes, com o número de repetições ajustado por um critério de precisão (Campelo e Takahashi, 2019). A diferença de desempenho médio, em escala logarítmica, foi avaliada por um teste t pareado e confirmada por testes não paramétricos. A configuração 1 (`recombination_lbga`, $F = 4{,}5$) obteve melhor desempenho em todas as 34 instâncias ($p < 0{,}001$), com `Fbest` em média 2,5 vezes menor (IC 95%: 1,8 a 3,6) e efeito padronizado $\hat{d} = 0{,}92$, superior a d^*. Recomenda-se a configuração 1 para a classe estudada, com a ressalva de que a vantagem diminui com a dimensão do problema.

1 Introdução

Algoritmos baseados em populações são frequentemente utilizados em problemas de otimização em engenharia. Neles, um conjunto de soluções candidatas é submetido iterativamente a operadores de variação e seleção, explorando o espaço de busca em direção ao mínimo (ou máximo) de uma função objetivo.

Entre esses algoritmos, destaca-se o método de **evolução diferencial** (DE, do inglês *Differential Evolution*), proposta por Storn e Price (1997), cujo funcionamento pode ser resumido assim:

Entrada: N (tamanho da população), n_{iter} (número de iterações), recpars e mutpars (parâmetros de recombinação e mutação).

1. **Inicialização:** $t \leftarrow 0$; gerar a população inicial $X_t = \{\vec{x}_1, \ldots, \vec{x}_N\}$ e avaliar $\vec{f}_t \leftarrow f(X_t)$.
2. **Enquanto** $t < n_{\text{iter}}$:
    1. **Mutação:** $V_t \leftarrow \text{mutação}(X_t, \text{mutpars})$
    2. **Recombinação:** $U_t \leftarrow \text{recombinação}(X_t, V_t, \text{recpars})$
    3. **Avaliação:** $\vec{j}_t \leftarrow f(U_t)$
    4. **Seleção:** $(X_{t+1}, \vec{f}_{t+1}) \leftarrow \text{seleção}(X_t, U_t, \vec{f}_t, \vec{j}_t)$
    5. $t \leftarrow t + 1$
3. **Saída:** população final e valores da função objetivo, $(X_t, \vec{f}_t)$.

Neste estudo, o critério de parada é um número máximo de avaliações da função objetivo ($5000 \cdot \dim$), e o desempenho de cada execução é medido pelo melhor valor encontrado (`Fbest`). Valores menores indicam melhor desempenho.

O objetivo é comparar duas configurações do DE na classe de problemas formada pelas funções de Rosenbrock com dimensão entre 2 e 150. Cada configuração combina um operador de recombinação e um de mutação.

Neste caso de estudo particular, ambas configurações usam a mutação `mutation_rand`, mas com fatores de escala F diferentes:

- **Configuração 1:** recombinação por linha (*line recombination*) do *Breeder Genetic Algorithm* (BGA), `recombination_lbga`; mutação *rand* com $F = 4{,}5$.
- **Configuração 2:** *Blend Crossover* Alpha-Beta (BLX-$\alpha\beta$), `recombination_blxAlphaBeta`, com $\alpha = 0{,}1$ e $\beta = 0{,}4$; mutação *rand* com $F = 3$.

2 Planejamento do Experimento

2.1 Objetivo e hipóteses

O objetivo deste experimento é responder a três perguntas:

1. Existe diferença no desempenho médio das duas configurações na classe de problemas considerada?
2. Se existir, qual configuração é melhor e qual a magnitude da diferença?
3. Os resultados justificam recomendar uma configuração em relação à outra?

Seja Y_{ij} o desempenho médio da configuração i na instância j, correspondente a uma função de Rosenbrock de dimensão específica. Para comparar as duas configurações em uma mesma instância, define-se a diferença pareada de desempenho como:

$$\psi_j = \bar{Y}_{2j} - \bar{Y}_{1j}$$

Como o desempenho é avaliado pelo valor de `Fbest`, que deve ser minimizado, valores de $\psi_j > 0$ indicam que a configuração 1 apresentou melhor desempenho, enquanto valores de $\psi_j < 0$ favorecem a configuração 2.

Assim, define-se $\mu_D = E[\psi_j]$ como a diferença média esperada de desempenho entre as duas configurações, considerando o conjunto de instâncias avaliadas. Desta forma, as hipóteses a serem testadas a fim de responder às perguntas do experimento são:

$$\begin{cases} H_0 : \mu_D = 0 \\ H_1 : \mu_D \neq 0 \end{cases}$$

Nelas, H_0 estabelece que não há diferença média de desempenho entre as duas configurações, enquanto H_1 admite diferença em qualquer direção. Já o sinal da estimativa de μ_D e seu intervalo de confiança indicarão qual configuração é melhor, caso H_0 seja rejeitada.

2.2 Coleta dos dados e Tamanho amostral

O planejamento do experimento exige a definição de dois tamanhos amostrais, seguindo a metodologia de Campelo e Takahashi (2019):

1. o número de instâncias, N, suficiente para detectar a diferença de interesse e representativo da classe de problemas, isto é, funções de Rosenbrock com dimensão entre 2 e 150;
2. o número de repetições de cada configuração em cada instância, n_{ij}, que permita estimar com precisão adequada o desempenho médio da configuração i na instância j.

2.2.1 Número de instâncias (N)

O enunciado do estudo de caso (Bessani, 2026) estabelece os seguintes parâmetros experimentais:

- Mínima diferença de importância prática (padronizada): $d^* = \delta^*/\sigma = 0{,}5$
- Nível de significância: $\alpha = 0{,}05$
- Potência mínima (para $d = d^*$): $\pi = 1 - \beta = 0{,}8$

Com base nesses valores, realizou-se uma análise de potência para o teste t pareado bilateral, a fim de determinar o menor número de instâncias capaz de detectar uma diferença de importância prática com o nível de significância e a potência especificados. Como d^* já é uma quantidade padronizada, utilizaram-se `delta = 0.5` e `sd = 1`.

O resultado (`power.t.test`, tipo pareado, bilateral) foi $n = 33{,}4$, que, arredondado para cima, corresponde a $N^* = 34$ instâncias. As duas configurações são avaliadas nas mesmas instâncias, o que garante o pareamento dos dados.

Para que as instâncias constituam uma amostra representativa da classe de problemas, as $N^* = 34$ dimensões foram sorteadas aleatoriamente, sem reposição, entre os inteiros de 2 a 150, com semente fixa para garantir a reprodutibilidade. As instâncias avaliadas são apresentadas a seguir:

Dimensões selecionadas: 4, 9, 13, 32, 35, 36, 39, 43, 45, 46, 49, 57, 59, 62, 67, 80, 89, 92, 94, 99, 100, 101, 102, 109, 111, 112, 114, 115, 122, 127, 131, 132, 134, 148.

2.2.2 Número de repetições (n_{ij})

Para determinar o número de repetições de cada configuração em cada instância, implementou-se o Algoritmo 1 de Campelo e Takahashi (2019). Em cada instância, o algoritmo executa inicialmente n_0 repetições de cada configuração e, em seguida, acrescenta uma repetição por vez até que o erro padrão da diferença de desempenho ψ_j atinja a precisão desejada, ou até que um orçamento máximo de execuções, n_{max}, seja alcançado. As repetições adicionais são alocadas preferencialmente à configuração de maior variância, de modo que n_{1j} e n_{2j} podem ser diferentes.

Quanto a n_0, os autores recomendam basear a escolha na forma da distribuição do desempenho do algoritmo: valores baixos (3 ou 4) para distribuições aproximadamente gaussianas, em torno de 10 para outras distribuições simétricas e 20 ou 30 para distribuições fortemente assimétricas. Adotou-se $n_0 = 20$, valor que atende bem à maioria dos casos. Nas instâncias em que a variabilidade é maior, o algoritmo acrescenta repetições até alcançar a precisão desejada. O orçamento máximo foi fixado em $n_{max} = 200$ execuções por instância, somando as duas configurações.

A precisão desejada foi definida a partir de um estudo piloto, seguindo a Seção 4.6 de Campelo e Takahashi (2019). Sortearam-se 8 instâncias fora da amostra principal (dimensões 47, 50, 58, 120, 123, 128, 142, 145) e executaram-se 15 repetições de cada configuração em cada uma, obtendo-se uma estimativa inicial do desvio padrão das diferenças entre instâncias, $\hat{\sigma}_\psi = 0{,}266$. O erro padrão máximo admitido para cada ψ_j foi fixado em $se^* = \sqrt{0{,}1}\,\hat{\sigma}_\psi = 0{,}084$, de modo que a incerteza das repetições contribua com no máximo 10% da variância entre instâncias. A Tabela 3, no Apêndice, mostra o resultado: 31 das 34 instâncias atingiram esse alvo com as 20 execuções iniciais por configuração; as dimensões 9 e 13 exigiram mais repetições, e a dimensão 4 esgotou o orçamento de 200 execuções com erro padrão ainda acima do alvo.

3 Análise exploratória e tratamento dos dados

As inferências deste experimento são realizadas sobre ψ_j, a diferença de desempenho médio entre as configurações na instância j. Por isso, os dados brutos obtidos das execuções do algoritmo passaram por duas etapas de processamento:

1. para cada dimensão (instância), calculou-se o desempenho médio de cada configuração, $\bar{F}_{1j}$ e $\bar{F}_{2j}$, a partir das n_{1j} e n_{2j} repetições do melhor valor encontrado (`Fbest`);
2. a partir dessas médias, calculou-se a diferença $\psi_j^{\text{bruto}} = \bar{F}_{2j} - \bar{F}_{1j}$, observação amostral da diferença de desempenho na instância j, na escala original.

A Figura 1 apresenta as diferenças entre as médias de desempenho das configurações em cada instância avaliada. Observa-se que as diferenças são maiores nas instâncias de maior dimensão. Isso não deve ser interpretado, por si só, como uma diferença maior entre as configurações, pois a ordem de grandeza dos valores da função de Rosenbrock cresce com a dimensão d (Pohlheim, 2005). Assim, diferenças absolutas tendem a crescer com d mesmo que a diferença relativa entre as configurações seja a mesma. Esse comportamento

pode ser constatado na Tabela 2, apresentada no Apêndice. A diferença de escala entre as instâncias motivou a verificação da normalidade das diferenças e a avaliação de uma transformação dos dados, descritas nas próximas seções.

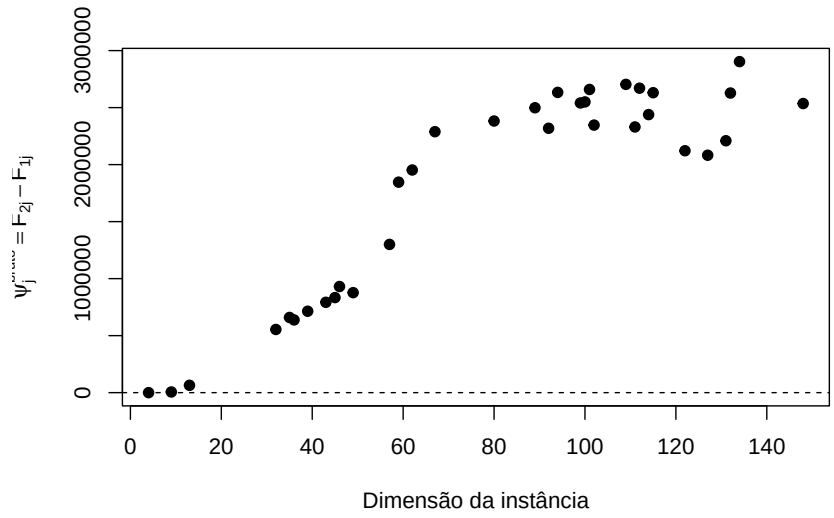


Figura 1: Diferença de desempenho médio entre as configurações em cada instância, em função da dimensão (escala original).

Para compreender melhor o comportamento dos dados, selecionou-se uma subamostra de 9 das 34 instâncias, distribuídas ao longo do intervalo de dimensões para representar instâncias de baixa, média e alta dimensão.

Dimensões selecionadas para a análise exploratória: 4, 9, 32, 49, 62, 92, 94, 102, 122.

A Figura 2 mostra os dados brutos de desempenho de ambas as configurações. Em linhas gerais, os dados indicam que:

- em todas as instâncias do subconjunto, a configuração 1 apresenta melhor desempenho, isto é, valores de `Fbest` menores;
- nas instâncias de menor dimensão o algoritmo alcança valores menores do que nas de maior dimensão, o que indica que é conveniente tratar os dados para colocar as instâncias em uma escala comparável.

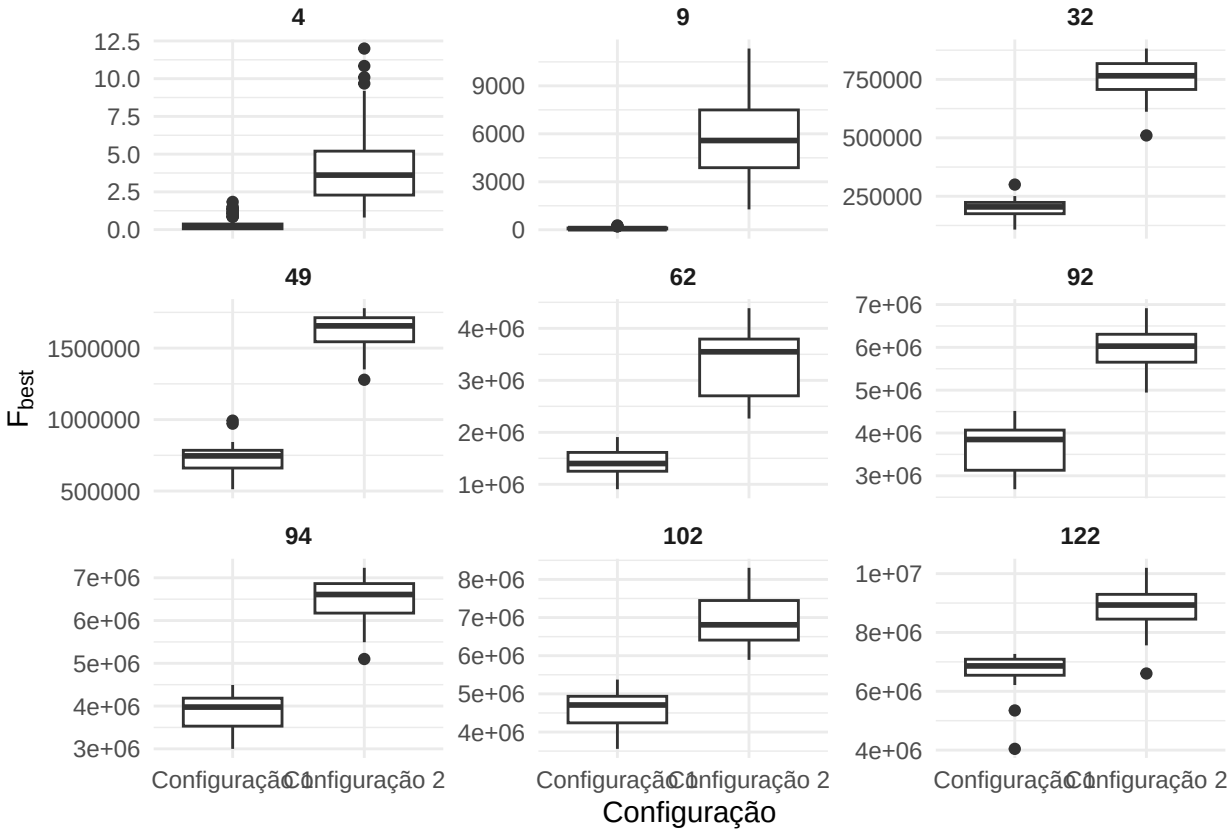


Figura 2: Distribuição do desempenho (Fbest) de cada configuração nas instâncias do subconjunto exploratório.

3.1 Normalidade das diferenças na escala original

O teste de Shapiro-Wilk rejeita a normalidade das diferenças ψ_j^{bruto} ($p < 0{,}001$). O gráfico quantil-quantil (Figura 3) mostra uma curva em forma de S, com um patamar em torno de 2,5 milhões, coerente com o efeito da escala descrito anteriormente.

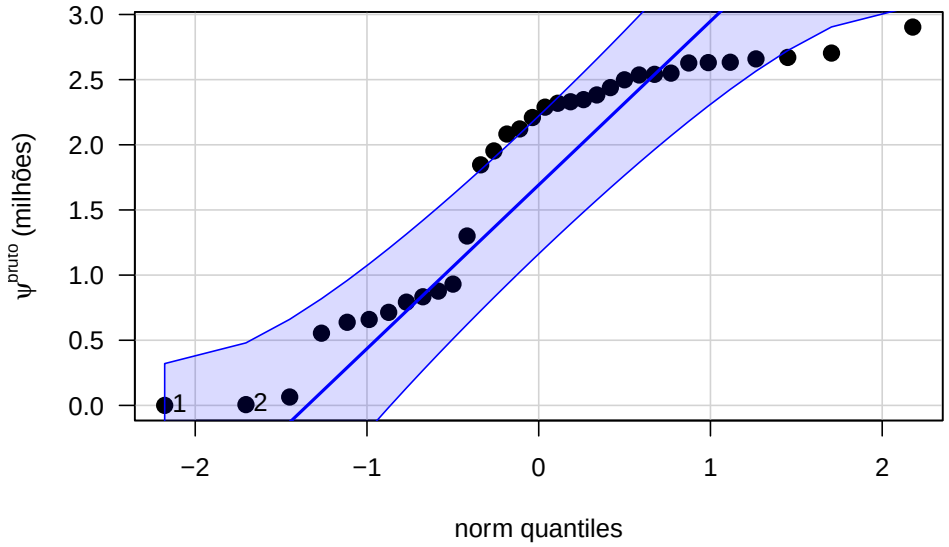


Figura 3: Gráfico quantil-quantil das diferenças de desempenho na escala original.

3.2 Transformação logarítmica

Como a ordem de grandeza de `Fbest` varia fortemente com a dimensão, as diferenças foram calculadas sobre o logaritmo natural do desempenho. Define-se

$$\bar{Y}_{ij} = \frac{1}{n_{ij}} \sum_{k=1}^{n_{ij}} \log(F_{best,ijk}), \qquad \psi_j = \bar{Y}_{2j} - \bar{Y}_{1j},$$

em que $F_{best,ijk}$ é o valor obtido na repetição k da configuração i na instância j. A transformação foi definida no planejamento (script `ec03_experimento.R`), antes da coleta, com dois objetivos: colocar as instâncias em escala comparável, como recomenda Montgomery (2017, Seção 3.4.3) para respostas cuja dispersão cresce com a média, e tornar a diferença interpretável, já que a diferença de logaritmos corresponde ao logaritmo da razão entre os desempenhos. Como a diferença mínima de importância prática $d^* = \delta^*/\sigma$ é adimensional, ela se aplica igualmente à escala transformada.

Após a transformação, o teste de Shapiro-Wilk ainda rejeita a normalidade ($p < 0{,}001$). No entanto, como mostra a Figura 4, a maior parte dos pontos acompanha a reta do gráfico quantil-quantil, e o desvio é provocado principalmente pelas três instâncias de menor dimensão (4, 9, 13), nas quais a diferença entre as configurações é muito maior do que nas demais.

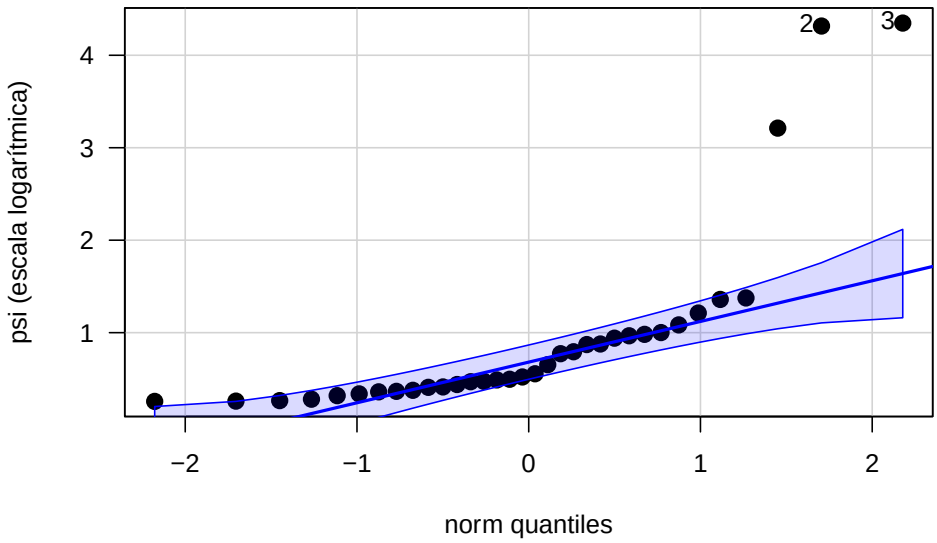


Figura 4: Gráfico quantil-quantil das diferenças de desempenho na escala logarítmica.

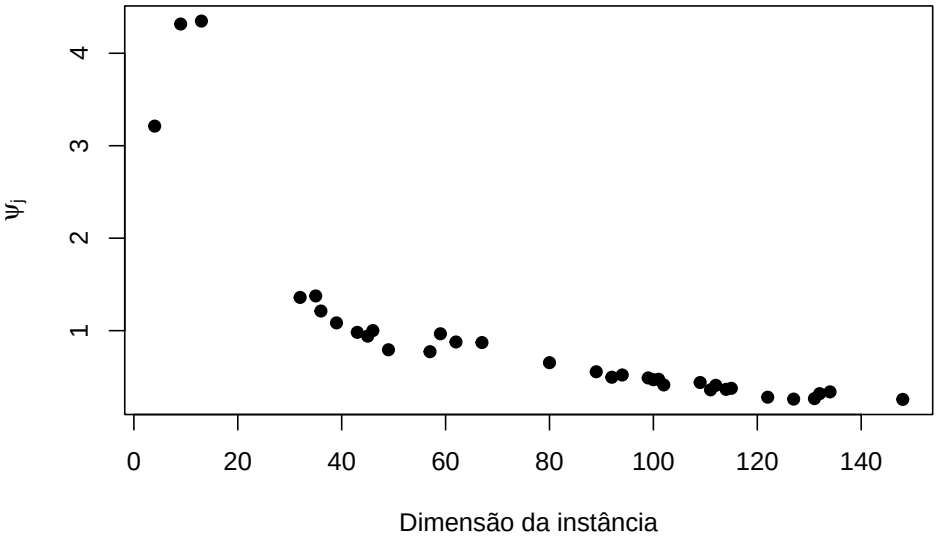


Figura 5: Diferença de desempenho na escala logarítmica, em função da dimensão.

4 Análise Estatística

A análise usa as 34 diferenças ψ_j na escala logarítmica (Seção 3), uma por instância, com $\alpha = 0{,}05$. As repetições servem apenas para estimar cada ψ_j; tratá-las como observações independentes seria

pseudorreplicação (Campelo e Takahashi, 2019).

4.1 Teste de hipóteses

As hipóteses definidas na Seção 2 são:

- **Hipótese nula** ($H_0 : \mu_D = 0$): as duas configurações têm o mesmo desempenho médio;
- **Hipótese alternativa** ($H_1 : \mu_D \neq 0$): as duas configurações têm desempenho médio diferente.

Para testá-las, usou-se o teste t pareado bilateral, que equivale a um teste t de uma amostra sobre as diferenças ψ_j. A estatística do teste é a média das diferenças dividida pelo seu erro padrão, $t_0 = \bar{\psi}/(s_\psi/\sqrt{N})$, em que $\bar{\psi} = 0{,}937$ é a média e $s_\psi = 1{,}020$ é o desvio padrão das 34 diferenças. Com esses valores, $t_0 = 0{,}937/(1{,}020/\sqrt{34}) = 5{,}36$, com $N - 1 = 33$ graus de liberdade.

O p-valor é a chance de observar uma diferença média tão grande quanto essa se H_0 fosse verdadeira. Aqui, $p < 0{,}001$, bem abaixo de $\alpha = 0{,}05$.

Resultado: rejeita-se H_0 em favor de H_1, ou seja, há diferença no desempenho médio das duas configurações. Como $\bar{\psi} > 0$, a configuração 2 tem, em média, maior $\log(F_{best})$, e portanto a configuração 1 é a melhor. Ela obteve menor média de $\log(F_{best})$ em todas as 34 instâncias (Figura 5).

4.2 Verificação das premissas

O teste t pareado supõe independência entre os ψ_j e normalidade da distribuição amostral de $\bar{\psi}$.

- **Independência:** garantida pelo planejamento. As dimensões foram sorteadas sem reposição e cada instância contribui com um único ψ_j.
- **Normalidade:** o teste de Shapiro-Wilk rejeita a normalidade dos ψ_j ($p < 0{,}001$, Seção 3). Como a premissa se refere à média, a distribuição amostral de $\bar{\psi}$ foi estimada por *bootstrap* (Campelo e Takahashi, 2019): os 34 valores de ψ_j foram reamostrados com reposição 9999 vezes, calculando-se a média de cada reamostra. No gráfico quantil-quantil dessas médias (Figura 6), os pontos acompanham a reta no centro, mas se curvam para cima nas duas extremidades. Isso indica assimetria à direita, causada pelas três instâncias atípicas da Seção 3. Logo, o p-valor e o intervalo de confiança do teste t são aproximados.

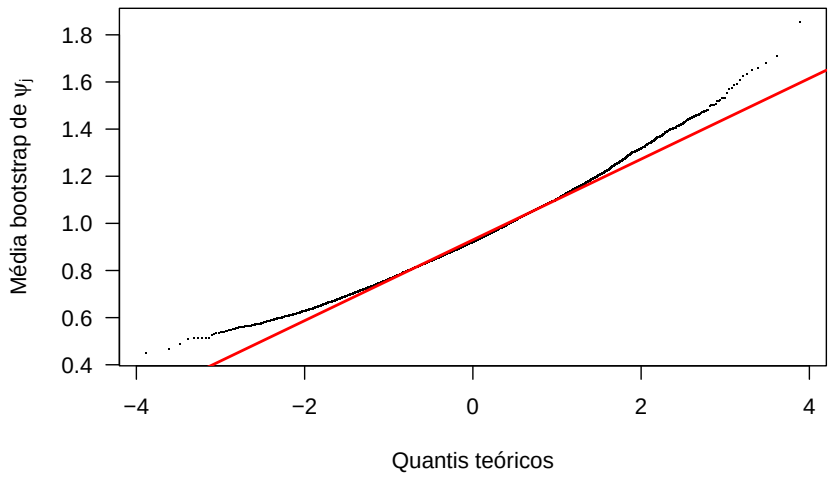


Figura 6: Gráfico quantil-quantil das médias bootstrap das diferenças ψ_j (9999 reamostragens).

Para confirmar a conclusão sem depender da normalidade, aplicou-se o teste do sinal, que exige apenas independência. O teste conta em quantas instâncias a configuração 1 foi melhor ($\psi_j > 0$): foram 34 de 34. Se H_0 fosse verdadeira, cada instância teria 50% de chance de favorecer cada configuração, como no lançamento de uma moeda. A chance de todas as 34 favorecerem a mesma configuração seria de $2 \times 0{,}5^{34}$, em que o fator 2 conta os dois casos possíveis (todas a favor da configuração 1 ou todas a favor da configuração 2). Esse valor é o p-valor do teste, e $p < 0{,}001$. Portanto, o teste do sinal também rejeita H_0.

Como verificação intermediária entre os dois, aplicou-se também o teste de Wilcoxon pareado, que usa os postos das diferenças em vez de seus valores e exige apenas que a distribuição das diferenças seja simétrica. O teste rejeita H_0 ($p < 0{,}001$), e seu intervalo de confiança de 95% para a mediana das diferenças vai de 0,53 a 0,88, também inteiramente positivo. Os três testes concordam.

4.3 Magnitude da diferença

A diferença média estimada, na escala logarítmica, é $\hat{\mu}_D = 0{,}94$. O IC 95% do teste t é calculado por $\bar{\psi} \pm t_{0{,}975;\,33} \cdot s_\psi/\sqrt{N}$, em que $t_{0{,}975;\,33} = 2{,}035$ é o valor crítico da distribuição t. Com os dados, $0{,}937 \pm 2{,}035 \times 1{,}020/\sqrt{34}$, o intervalo vai de 0,58 a 1,29. Pelo *bootstrap* percentil, que não supõe normalidade, o IC 95% vai do percentil 2,5% ao 97,5% das 9999 médias bootstrap, de 0,63 a 1,31. Os dois intervalos contêm apenas valores positivos, isto é, favorecem a configuração 1.

O efeito padronizado é a média dividida pelo desvio padrão das diferenças: $\hat{d} = 0{,}937/1{,}020 = 0{,}92$. Esse valor é maior que a mínima diferença de importância prática, $d^* = 0{,}5$, e portanto a diferença também é relevante na prática.

Por fim, para entender a magnitude na escala original do `Fbest`, aplica-se a exponencial, que é o inverso do logaritmo. Como ψ_j é uma diferença de logaritmos, a exponencial de $\bar{\psi}$ é uma razão entre os desempenhos: $e^{0{,}937} = 2{,}55$. Ou seja, em média (geométrica), o `Fbest` da configuração 2 é 2,55 vezes o da configuração 1. Dito de outra forma, a configuração 1 obtém um `Fbest` cerca de 61% menor. Aplicando a exponencial aos limites do IC 95% do teste t, a razão fica entre 1,79 e 3,64, o que corresponde a um `Fbest` de 44% a 73% menor com a configuração 1.

5 Conclusões e Recomendações

Os resultados respondem às três perguntas do experimento da seguinte forma.

1. **Existe diferença?** Sim. O teste t pareado rejeitou $H_0 : \mu_D = 0$ ($p < 0{,}001$), e os testes de Wilcoxon e do sinal, que não exigem normalidade, chegaram à mesma conclusão: a configuração 1 foi melhor em 34 de 34 instâncias ($p < 0{,}001$).
2. **Qual é melhor e por quanto?** A configuração 1 (`recombination_lbga`, $F = 4{,}5$) é melhor. A diferença média na escala logarítmica é $\hat{\mu}_D = 0{,}94$, com IC 95% de 0,58 a 1,29 (teste t) e de 0,63 a 1,31 (*bootstrap*). Em média geométrica, o `Fbest` da configuração 2 é cerca de 2,55 vezes o da configuração 1 (IC 95%: 1,79 a 3,64), ou seja, a configuração 1 obtém um `Fbest` cerca de 61% menor. O efeito padronizado estimado, $\hat{d} = 0{,}92$, supera a diferença de importância prática $d^* = 0{,}5$, de modo que a diferença é relevante, e não apenas estatisticamente significativa.
3. **Os resultados justificam uma recomendação?** Sim: recomenda-se a configuração 1 para a classe de funções de Rosenbrock com dimensão entre 2 e 150. A conclusão é robusta: o IC 95% fica inteiramente acima de zero pelos dois métodos, e a configuração 1 venceu em todas as instâncias. Mesmo retirando as três instâncias atípicas (dimensões 4, 9, 13), o resultado se mantém ($p < 0{,}001$, razão de 1,90, isto é, `Fbest` cerca de 47% menor).

Ressalvas. A magnitude da vantagem não é uniforme. A diferença ψ_j diminui com a dimensão (correlação de Spearman de $-0{,}98$): a razão entre os desempenhos vai de aproximadamente 77 vezes na instância mais favorável à configuração 1 até 1,29 vezes na menos favorável. Assim, a razão média de 2,55 resume bem o conjunto, mas superestima a vantagem em dimensões altas e subestima em dimensões baixas. A recomendação vale para toda a faixa testada, porém o ganho é muito maior em dimensões baixas, e, para

dimensões altas, a vantagem, embora presente, é modesta. Além disso, as conclusões se restringem às duas configurações comparadas, ao critério de parada de $5000 \cdot \dim$ avaliações e a funções de Rosenbrock. Não se pode concluir que o `recombination_lbga` seja superior ao `recombination_blxAlphaBeta` em geral, pois os dois fatores (recombinação e F) variam simultaneamente entre as configurações e seus efeitos não podem ser separados.

6 Discussão da significância e dos riscos do teste

6.1 Nível de significância e controle do erro tipo I

O nível de significância adotado foi $\alpha = 0{,}05$, o que significa aceitar uma probabilidade de 5% de rejeitar H_0 quando ela é verdadeira (erro tipo I), isto é, de concluir que há diferença quando as configurações são equivalentes. Como o experimento tem uma única hipótese principal, não há problema de comparações múltiplas e não foi necessária correção de α. O p-valor obtido ($p < 0{,}001$) está muito abaixo de 0,05, de modo que o risco de erro tipo I nesta conclusão é pequeno.

Esse risco, porém, depende de o teste t manter seu nível nominal, e isso é só aproximadamente garantido aqui, porque a normalidade dos ψ_j foi rejeitada e a distribuição de $\bar{\psi}$ mostra assimetria à direita (Seção 4.2). Por isso a conclusão não foi baseada apenas no teste t. Os testes de Wilcoxon e do sinal, que não dependem da normalidade, e o IC *bootstrap* levaram à mesma decisão, e o resultado persiste sem as instâncias atípicas. A independência entre os ψ_j é garantida pelo sorteio aleatório das dimensões. Dessa forma, é improvável que a violação da normalidade tenha produzido uma rejeição espúria de H_0.

6.2 Erro tipo II e potência dos testes

O erro tipo II é deixar de rejeitar H_0 quando existe uma diferença real. O experimento foi planejado para que sua probabilidade fosse de no máximo $\beta = 0{,}2$ (potência de 80%) para diferenças de pelo menos $d^* = 0{,}5$, o que levou a $N^* = 34$ instâncias. Com $N = 34$, a potência efetiva do teste t pareado nesse cenário é de 81%.

Como H_0 foi rejeitada, o erro tipo II não afeta a conclusão principal: ele só importaria se o resultado tivesse sido não significativo, caso em que não se poderia afirmar que as configurações são equivalentes. A diferença observada ($\hat{d} = 0{,}92$) é bem maior que a de planejamento, o que explica a rejeição com p-valor tão pequeno. É preciso lembrar, porém, que essa potência refere-se ao teste t sob normalidade e foi calculada para d^* padronizado sobre os ψ_j na escala logarítmica. Para comparações com configurações mais parecidas entre si, em que se esperaria $d < d^*$, o mesmo N seria insuficiente para garantir a detecção. Vale notar ainda que o N foi dimensionado para o teste t; para o teste de Wilcoxon, cuja eficiência é um pouco menor, seriam necessárias cerca de 40 instâncias para a mesma potência nominal.

7 Possíveis melhorias do experimento

- **Separar os fatores.** As duas configurações diferem na recombinação e em F ao mesmo tempo, de modo que não é possível atribuir a diferença a um deles. Um planejamento fatorial 2^2 (recombinação $\times$ F), mantendo as instâncias como blocos, permitiria estimar o efeito de cada fator e sua interação.
- **Modelar a dimensão.** A diferença ψ_j decresce com a dimensão, o que a média única não captura. Uma regressão de ψ_j sobre $\log(\dim_j)$ descreveria a magnitude da vantagem ao longo da classe; alternativamente, sortear as dimensões por faixas (baixa, média e alta) garantiria cobertura uniforme, já que apenas 3 das 34 instâncias ficaram abaixo de $\dim = 30$.
- **Piloto mais representativo.** O piloto usou 8 instâncias, nenhuma abaixo de $\dim = 47$, e subestimou a variabilidade em dimensões baixas: a dimensão 4 esgotou o orçamento de 200 execuções sem atingir a precisão alvo. Um piloto com instâncias de todas as faixas de dimensão definiria um se^* e um n_0 mais adequados, otimizando o uso do recurso computacional.
- **Tamanho amostral para o teste não paramétrico.** Como a normalidade das diferenças foi rejeitada, N poderia ter sido calculado para o teste de Wilcoxon, o que exigiria cerca de 40 instâncias

para manter a potência de 0,8.

8 Papéis desempenhados pela equipe

Tabela 1: Papéis desempenhados pelos integrantes da equipe.

Integrante	Papel
Adonai Arruda	Coordenador e Relator: estruturação do repositório, implementação do algoritmo de amostragem e execução do experimento, redação da análise estatística e integração das contribuições da equipe.
Alexandra Milaya Soto Aponte	Programadora/Analista: redação da introdução, do planejamento do experimento e da análise exploratória dos dados, incluindo o cálculo do tamanho amostral.
João Paulo Gonçalves Simim	Analista/Verificador: revisão metodológica, documentação do estudo piloto, redação do resumo e das sugestões de melhoria, compilação independente do relatório e envio.
Yasmim Machado	Redatora e Verificadora: redação das conclusões e da discussão de significância e riscos, referências e revisão do texto final.

9 Declaração sobre o uso de IA generativa

Durante a preparação deste trabalho, os autores utilizaram o Claude (Anthropic) como apoio à implementação do código em R, à redação inicial de partes do texto e à revisão metodológica e de formatação do relatório. Após utilizar essa ferramenta, os autores revisaram, editaram e finalizaram o conteúdo, conferiram todos os cálculos e conclusões e assumem total responsabilidade pelo conteúdo da publicação.

10 Referências

- BESSANI, M. Material da disciplina EEE933 - Planejamento e Análise de Experimentos (notas de aula sobre comparações pareadas, testes não paramétricos e blocagem). PPGEE/UFMG, 2026.
- BOSSEK, J. smoof: Single- and Multi-Objective Optimization Test Functions. *The R Journal*, v. 9, n. 1, p. 103–113, 2017.
- CAMPELO, F.; BOTELHO, M. Experimental Investigation of Recombination Operators for Differential Evolution. In: *Proceedings of the Genetic and Evolutionary Computation Conference (GECCO '16)*, 2016.
- CAMPELO, F.; TAKAHASHI, F. Sample size estimation for power and accuracy in the experimental comparison of algorithms. *Journal of Heuristics*, v. 25, p. 305–338, 2019.
- MONTGOMERY, D. C. *Design and Analysis of Experiments*. 9. ed. John Wiley & Sons, 2017.
- POHLHEIM, H. Examples of Objective Functions. GEATbx, 2005. Disponível em: http://www.geatbx.com/download/GEATbx_ObjFunExpl_v37.pdf.
- ROSENBROCK, H. H. An Automatic Method for Finding the Greatest or Least Value of a Function. *The Computer Journal*, v. 3, n. 3, p. 175–184, 1960.
- STORN, R.; PRICE, K. Differential Evolution: A Simple and Efficient Heuristic for Global Optimization over Continuous Spaces. *Journal of Global Optimization*, v. 11, n. 4, p. 341–359, 1997.

Dim.	Média Config. 1	n1	Média Config. 2	n2	Dif. (psi bruto)
4	0,3	136	4,2	64	3,9
9	85,8	99	5.949,0	75	5.863,2
13	922,5	80	65.316,9	54	64.394,3
32	196.419,1	20	750.629,9	20	554.210,8
35	237.681,4	20	897.031,1	20	659.349,7
36	276.990,4	20	914.858,1	20	637.867,6
39	370.934,0	20	1.085.031,3	20	714.097,3
43	500.132,1	20	1.292.477,7	20	792.345,6
45	555.662,3	20	1.389.235,9	20	833.573,6
46	556.527,0	20	1.487.269,0	20	930.741,9
49	736.880,9	20	1.613.800,4	20	876.919,5
57	1.146.780,7	20	2.446.673,4	20	1.299.892,7
59	1.140.902,5	20	2.986.936,0	20	1.846.033,5
62	1.390.624,7	20	3.343.388,1	20	1.952.763,4
67	1.677.880,7	20	3.966.622,3	20	2.288.741,6
80	2.658.236,3	20	5.040.590,0	20	2.382.353,7
89	3.382.518,5	20	5.881.098,2	20	2.498.579,7
92	3.695.349,7	20	6.014.122,7	20	2.318.772,9
94	3.871.183,8	20	6.504.508,4	20	2.633.324,6
99	4.133.132,9	20	6.673.817,1	20	2.540.684,3
100	4.303.422,7	20	6.853.335,7	20	2.549.913,0
101	4.462.125,5	20	7.121.242,9	20	2.659.117,4
102	4.599.981,4	20	6.946.558,4	20	2.346.577,1
109	4.928.367,4	20	7.632.129,9	20	2.703.762,5
111	5.433.973,7	20	7.764.173,0	20	2.330.199,3
112	5.370.913,1	20	8.041.262,9	20	2.670.349,8
114	5.675.794,0	20	8.114.446,0	20	2.438.652,0
115	5.795.081,3	20	8.425.711,5	20	2.630.630,2
122	6.653.460,5	20	8.775.082,0	20	2.121.621,5
127	7.046.260,3	20	9.128.671,1	20	2.082.410,8
131	7.334.573,9	20	9.543.824,8	20	2.209.250,9
132	7.142.759,3	20	9.770.546,0	20	2.627.786,7
134	7.337.425,3	20	10.240.711,5	20	2.903.286,2
148	8.765.676,6	20	11.301.341,9	20	2.535.665,3

Tabela 2: Desempenho médio (escala original) e número de repetições por instância.

11 Apêndice: desempenho médio por instância

Dim.	psi (log)	Erro padrão	n1	n2	Atingiu se*
4	3,212	0,145	136	64	não
9	4,316	0,084	99	75	sim
13	4,348	0,084	80	54	sim
32	1,359	0,062	20	20	sim
35	1,375	0,079	20	20	sim
36	1,212	0,057	20	20	sim
39	1,084	0,044	20	20	sim
43	0,982	0,067	20	20	sim
45	0,940	0,062	20	20	sim
46	1,001	0,056	20	20	sim
49	0,793	0,043	20	20	sim
57	0,772	0,074	20	20	sim
59	0,966	0,065	20	20	sim
62	0,877	0,061	20	20	sim
67	0,871	0,050	20	20	sim
80	0,654	0,054	20	20	sim
89	0,555	0,037	20	20	sim
92	0,496	0,043	20	20	sim
94	0,521	0,032	20	20	sim
99	0,488	0,040	20	20	sim
100	0,469	0,030	20	20	sim
101	0,474	0,036	20	20	sim
102	0,413	0,035	20	20	sim
109	0,439	0,030	20	20	sim
111	0,360	0,038	20	20	sim
112	0,408	0,039	20	20	sim
114	0,365	0,038	20	20	sim
115	0,376	0,027	20	20	sim
122	0,280	0,038	20	20	sim
127	0,260	0,028	20	20	sim
131	0,265	0,032	20	20	sim
132	0,319	0,035	20	20	sim
134	0,338	0,027	20	20	sim
148	0,257	0,025	20	20	sim

Tabela 3: Resultado do procedimento de amostragem por instância: diferença em escala logarítmica, seu erro padrão, número de execuções de cada configuração e se o alvo de precisão foi atingido.