

Planejamento e Análise de Experimentos

3 - Estimação Pontual

Michel Bessani

<https://orcslab.github.io/>

Departamento de Engenharia Elétrica - DEE

Programa de Pós-Graduação em Engenharia Elétrica - PPGEE



UNIVERSIDADE FEDERAL
DE MINAS GERAIS

Belo Horizonte

- 1. Introdução
 - 1.1 Definições
- 2. Estimação Pontual
 - 2.1 Estimadores Não-Tendenciosos
- 3. Teorema Central do Limite
- 4. Referências

Introdução

Inferência Estatística

Utilizar amostras para tomar decisões e obter conclusões sobre uma população.

Como esse procedimento é feito normalmente?

Como faríamos para avaliar uma propriedade específica de um processo, sistema ou componente?

A variabilidade é inerente: insumos, matéria-prima, operação, meio, medição, entre outros fatores.

Vamos assumir que decidimos por caracterizar essa propriedade específica pelo seu valor médio.

Coleta-se uma amostra $\mathbf{x} = \{x_1, \dots, x_n\}$ e então calcula-se a média amostral $\bar{X}$.

Esse procedimento de estimar uma característica populacional a partir de uma amostra é chamado de **estimação pontual**.

Introdução: Definições

Probabilidade: Qual a probabilidade de se obter uma certa combinação de cores?



Estatística: O que é possível dizer sobre o conjunto de bolinhas?



- ▶ **População:** Conjunto de elementos de natureza similar que constitui o fenômeno ou processo de interesse em um estudo. Este pode ser um conjunto físico ou não.



- ▶ **Amostra:** Subconjunto da população, geralmente obtido para se fazer inferência sobre a população;



- ▶ **Observação:** elemento único de uma dada amostra ou um ponto coletado individualmente.



O procedimento de coletar uma amostra $\mathbf{x} = \{x_1, \dots, x_n\}$ de forma aleatorizada a partir de uma mesma população resulta em uma **amostra aleatória**.

Amostra Aleatória

Um conjunto de observações forma uma amostra aleatória, se e somente se, as observações forem **iid**:

1. **Independentes**: o próximo valor a ser observado não depende dos valores observados anteriormente;
2. **Identicamente distribuídas**: todos os valores seguem uma mesma distribuição de probabilidade.

Qualquer **número calculado** a partir de uma **amostra aleatória** (iid) é uma **estatística**.

Dessa forma, sempre que repetirmos um experimento obteremos uma nova amostra aleatória, e conseqüentemente, um novo valor para a estatística escolhida.

A distribuição de probabilidade de uma **estatística** é chamada de **Distribuição Amostral**.

Estimação Pontual

Considere uma amostra aleatória $\mathbf{x} = \{x_1, \dots, x_n\}$ obtida a partir de uma variável aleatória X que segue uma distribuição de probabilidade $f(x)$ com um conjunto $\theta = \{\theta_1, \dots, \theta_k\}$ de parâmetros desconhecidos.

Uma função $\hat{\Theta} = h(\mathbf{x})$ é um **estimador pontual** do parâmetro θ_i , e o valor retornado por essa função para uma dada **amostra aleatória** é uma **estimativa pontual** $\hat{\theta}_i$ desse parâmetro.

Estimação Pontual

Um estimador pontual $\hat{\theta}$ é qualquer estatística que fornece o valor mais plausível para um parâmetro populacional θ (desconhecido).

Problemas de estimação pontual surgem frequentemente em todas as áreas da ciência sempre que precisamos realizar estimativas.

Alguns exemplos:

- ▶ A média populacional, μ ;
- ▶ A variância populacional, σ^2 ;
- ▶ Uma proporção populacional, p ;
- ▶ A diferença entre as médias de duas populações, $\mu_1 - \mu_2$;

Em cada um desses casos existem diferentes formas de realizar a estimativa.

A escolha do estimador é baseada nas propriedades de cada estatística.

Estimação Pontual:
Estimadores Não-Tendenciosos

Um bom estimador deve ser capaz de gerar estimativas que sejam próximas do valor real do parâmetro θ .

Um estimador $\hat{\Theta}$ é dito ser não-tendencioso ou não-enviesado (*unbiased*) se o seu valor esperado for o próprio parâmetro θ :

$$E \left[\hat{\Theta} \right] = \theta$$

ou ainda:

$$T = E \left[\hat{\Theta} \right] - \theta = 0$$

A diferença $T = E \left[\hat{\Theta} \right] - \theta$ é a tendência do estimador.

Os estimadores usuais da média e variância são exemplos de estimadores não-tendenciosos.

Seja $\mathbf{x} = \{x_1, \dots, x_n\}$ uma amostra aleatória de uma dada população X com média μ e variância σ^2 . É possível demonstrar que¹


$$E[\bar{X}] = E\left[\frac{1}{n} \sum_{i=1}^n x_i\right] = \mu$$

e:

$$E[s^2] = E\left[\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2\right] = \sigma^2$$

¹Para detalhes, veja S.D. Anderson (1999), Proof that Sample Variance is Unbiased: <http://git.io/vUn9N>.

É possível existir mais do que um estimador não-tendencioso para um parâmetro θ . Entretanto, as variâncias desses estimadores podem ser diferentes:



Uma escolha lógica seria escolher o estimador com a menor variância.

Esse estimador é chamado de **Estimador Não-Tendencioso e de Variância Mínima (ENTVM)**.

ENTVM são escolhidos por resultarem em estimativas $\hat{\theta}$ que são próximas do valor real θ .

Podemos utilizar o erro padrão de um estimador $\hat{\Theta}$ que corresponde ao desvio padrão desse estimador:

$$\sigma_{\hat{\Theta}} = \sqrt{\text{Var} [\hat{\Theta}]}$$

Quando o erro padrão é estimado de uma amostra aleatória ele é chamado de erro padrão estimado $\hat{\sigma}_{\hat{\Theta}}$.

As notações $s_{\hat{\Theta}}$ e $se(\hat{\Theta})$ também podem ser utilizadas.

Para os estimadores mais usuais relacionados com variáveis normalmente distribuídas:

$$\hat{\sigma}_{\bar{X}} = \frac{s}{\sqrt{n}}$$

$$\hat{\sigma}_{S^2} = s^2 \sqrt{\frac{2}{n-1}}$$

$$\hat{\sigma}_S = \frac{s}{\sqrt{2(n-1)}} + O\left(\frac{1}{n\sqrt{(n)}}\right) \approx \frac{s}{\sqrt{2(n-1)}}$$

Estimativas mais gerais do erro padrão para diferentes distribuições ou estatísticas podem ser obtidas através de estratégias de reamostragem ou resultados assintóticos.

Teorema Central do Limite

Mesmo para populações com distribuições arbitrárias, a distribuição amostral da média tende à normalidade ($E[\bar{X}] = \mu$ e $Var(\bar{X}) = \sigma^2/n$).

De forma geral, seja $\{x_1, \dots, x_n\}$ uma amostra aleatória (iid) de tamanho n de uma população com média μ e variância σ^2 , ambas finitas. A estatística (variável aleatória)

$$Z_n = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$$

converge para uma distribuição Normal Padrão ($\mathcal{N}(0, 1)$) quando $n \rightarrow \infty$, i.e., $Z_n \sim \mathcal{N}(0, 1)$.

A medida que n cresce, a distribuição amostral das médias amostrais de N amostras aleatórias, $\{\bar{X}_1, \dots, \bar{X}_N\}$ de tamanho n se aproxima da distribuição normal a medida que $N \rightarrow \infty$.

Esse resultado é consequência do **Teorema Central do Limite (TCL)**.

O TCL permite a utilização de técnicas baseadas nas características da Distribuição Normal mesmo que a população em estudo não siga uma Distribuição Normal.

Para distribuições bem comportadas (contínuas, simétricas e unimodais), mesmo amostras aleatórias pequenas, i.e., com poucas observações, são suficientes para justificar a utilização do TCL e, por consequência, as técnicas mais comuns de inferência.

Referências

- ▶ D.C. Montgomery, G.C. Runger (2010), *Applied Statistics and Probability for Engineers*, John Wiley & Sons.
- ▶ Felipe Campelo (2018), *Lecture Notes on Design and Analysis of Experiments*.
Online: <http://git.io/v3Kh8> Version 2.12; Creative Commons
BY-NC-SA 4.0.