

Planejamento e Análise de Experimentos

9 - Dados não Normais e Métodos não Paramétricos

Michel Bessani

Departamento de Engenharia Elétrica - DEE

Programa de Pós-Graduação em Engenharia Elétrica - PPGEE



UNIVERSIDADE FEDERAL
DE MINAS GERAIS

Belo Horizonte

Sumário

- 1. Introdução
- 2. Métodos não Paramétricos
 - 2.1 Quando utilizar Métodos não Paramétricos
 - 2.2 Testes dos Postos
 - 2.2.1 Teste do Sinal
 - 2.2.2 Teste de Wilcoxon
 - 2.3 Teste da Permutação
 - 2.4 Testes de Bootstrap
 - 2.5 Outros Métodos
- 3. Referências

Introdução

Vimos diferentes métodos de teste de hipóteses estatísticas e de estimativa de um intervalo de confiança.

Uma premissa necessária para aplicarmos todos os métodos é a de normalidade.

Em alguns casos, o TCL permite que um desvio de normalidade não seja um problema para inferências sobre a média, por exemplo, se nossa a.a. for composta por observações contínuas, simétricas e unimodais e com um número relativamente grande de observações.

Relembrando: Ao realizarmos um teste de hipóteses confrontamos duas opções:

A H_0 é “conservadora”, no sentido de que não existe novidade. Por exemplo, as especificações são atendidas ou uma nova versão de um processo não é diferente da anterior.

Já a definição da H_1 reflete a possibilidade de existirem novidades:

- ▶ Diferença de alguma especificação (velocidade, duração, consumo, etc.), H_1 bilateral;
- ▶ Aumento ou diminuição de alguma especificação, H_1 será unilateral ($>$ ou $<$).

$$\begin{cases} H_0 : \theta = \theta_0 \\ H_1 : \theta \neq \theta_0 \text{ ou } \theta < \theta_0 \text{ ou } \theta > \theta_0 \end{cases}$$

Ilustrando: Em um teste z bilateral (bilateral) ($H_1 : \mu \neq \mu_0$), estamos interessados na probabilidade $P(|Z| \geq \hat{z} | H_0)$.

Estamos assumindo as premissas de normalidade e variância conhecida para a amostra aleatória, assim $\hat{z} = (\bar{X} - \mu_0) / (\sigma / \sqrt{n})$ é a nossa estatística de teste e a mesma segue uma $\mathcal{N}(0, 1)$.

$P(|Z| \geq \hat{z} | H_0)$ significa a “probabilidade de observarmos um valor tão grande da estatística Z comparado ao $\hat{z}$ observado no experimento dado que H_0 seja verdadeira”. Essa probabilidade é o **p-valor**.

Fixamos um α (nível de significância) de tal maneira que se o p-valor $\leq \alpha$, rejeitamos a H_0 com um nível de confiança de $1 - \alpha$.

De forma geral, calcula-se $P(|T| \geq \hat{t} | H_0)$, onde $\hat{t}$ é uma estatística de teste escolhida de acordo com as hipóteses a serem testadas.

Quando testamos hipóteses utilizando um **método paramétrico**, comparamos a estatística de teste observada $\hat{t}$, que é uma função da a.a., com um valor tabelado dessa mesma estatística (t_α).

Um **método paramétrico** só deve ser realizado caso suas **premissas sejam atendidas**.

E se as premissas, e.g., de normalidade ou simetria não são atendidas?

Isso pode ocorrer ao final da coleta dos dados de um experimento em diversas situações práticas.

Como devemos proceder?

Transformar os dados é uma opção, mas pode não dar certo.

Testes paramétricos: Premissa de que a distribuição é conhecida (Normal, ou pelo menos simétrica) e estamos inferindo a respeito de parâmetros específicos da mesma:

- ▶ Média
- ▶ Variância

Como inferir sobre parâmetros genéricos, e.g., percentil 15%?

Utilizamos **métodos não paramétricos**, também conhecidos como **métodos livres de distribuição**, os quais assumem poucas suposições a respeito da distribuição que descreve o fenômeno de interesse.

Métodos não Paramétricos

Quando utilizar Métodos não Paramétricos

└ Métodos não Paramétricos

└ Quando utilizar Métodos não Paramétricos

- ▶ Não atendimento das premissas dos testes paramétricos;
- ▶ Testes paramétricos inconclusivos;
- ▶ Observações que refletem apenas:
 - Postos (especificação de ordem);
 - Contagem de número de eventos (e.g., Sim ou Não);
 - Contagem de indivíduos em diferentes categorias (e.g., Funcionando, em Falha ou em Manutenção).

Veremos os seguintes tipos de testes:

- ▶ Testes baseados em Postos (Ordem ou Ranqueamento);
- ▶ Testes de Permutação;
- ▶ Testes de Bootstrap.

Eles serão formalmente definidos e em seguida exemplificados.

Testes dos Postos

São testes onde se considera a **posição das observações** em relação à uma H_0 .

Os postos (posições) são o ranqueamento em ordem crescente das observações em relação ao valor considerado na H_0 .

Podem ser utilizados tanto para avaliar localização ou escala, como para proporções em realizações discretas.

Veremos em específico o **Teste do Sinal** e o **Teste de Wilcoxon**.

Relembrando - **Distribuição Binomial**: Utilizada quando temos apenas dois resultados possíveis em um experimento, “sucesso” ou “fracasso”, sendo p a probabilidade de um “sucesso” e $q = 1 - p$ a probabilidade de um “fracasso”.

A probabilidade de observarmos x sucessos em n observações é calculada como:

$$f(x) = \frac{n!}{x!(n-x)!} p^x q^{(n-x)}$$

De forma similar, a probabilidade de observarmos r ou menos sucessos em n repetições do experimento é:

$$F(r) = P(X \leq r) = \sum_{x=0}^r f(x) = \sum_{x=0}^r \frac{n!}{x!(n-x)!} p^x q^{(n-x)}$$

Teste do Sinal - Utilizado para testar se uma $H_0 : \theta = \theta_0$ é válida, onde θ é a mediana de uma distribuição.

Premissas:

- ▶ Amostras *iid*;
- ▶ Distribuição contínua.

Se H_0 for verdadeira, então as distâncias das observações em relação ao θ_0 serão distribuídos de forma equilibrada em torno de θ_0 .

Testamos se o número de observações com uma distância positiva em relação à θ_0 é plausível em uma distribuição binomial de n repetições do experimento com probabilidade de sucesso de 50%, $B(n, p = 0.5)$.

Teste do Sinal - Procedimento:

Dada um a.a. $\mathbf{X} = \{x_1, \dots, x_n\}$, deve-se:

1. Calcular a diferença entre cada x_i e θ_0 , obtendo uma nova a.a.
 $\mathbf{D} = \{D_1, \dots, D_n\}$;
2. Contabilizar o número de diferenças positivas,
 $r^+ = \sum_{i=1}^n \# \{D_i > 0\}$; $\#$ é a função indicadora
3. Calcular a probabilidade de obter um número tão extremo quanto r^+ em uma $B(n, p = 0.5)$.

Rejeitamos H_0 apenas se essa probabilidade for menor que um nível de significância α pré-estabelecido.

Teste do Sinal.

Dado $H_0 : \theta = \theta_0$, se queremos testar:

1. $H_1 : \theta < \theta_0$, então calculamos
p-valor = $P(R^+ \leq r^+ \text{ quando } p = 0.5)$;
2. $H_1 : \theta > \theta_0$, então calculamos
p-valor = $P(R^+ \geq r^+ \text{ quando } p = 0.5)$;
3. $H_1 : \theta \neq \theta_0$, então:
 - caso $r^+ < n/2$, p-valor = $2 \times P(R^+ \leq r^+ \text{ quando } p = 0.5)$;
 - caso $r^+ > n/2$, p-valor = $2 \times P(R^+ \geq r^+ \text{ quando } p = 0.5)$.

Teste do Sinal - Exemplo: Deseja-se verificar a durabilidade mediana de um componente eletromecânico com um $\alpha = 0.05$. O fabricante informou que a durabilidade esperada nas condições da aplicação é de 200 semanas.

Foram observados os seguintes tempos até falha em semanas:

$\mathbf{X} = \{49, 58, 75, 110, 112, 132, 151, 276, 281, 362\}$

É prudente informar que o tempo mediano até falha é de 200 semanas, ou esse tempo é menor do que 200?

$$\begin{cases} H_0 : \theta = 200 \\ H_1 : \theta < 200 \end{cases}$$

Adaptado de Sprent, P., & Smeeton, N. C. (2000). *Applied nonparametric statistical methods*.

Teste do Sinal - Exemplo:

A partir de $\mathbf{X} = \{49, 58, 75, 110, 112, 132, 151, 276, 281, 362\}$, calculamos $\mathbf{D} = \{-151, -142, -125, -90, -88, -68, -49, 76, 81, 162\}$

O número de observações que são maiores que θ_0 é $r^+ = 3$, e o p-valor será a probabilidade de observarmos 3 ou menos observações maiores que θ_0 dada que H_0 é verdadeiro.

$$\text{p-valor} = P(R^+ \leq r^+ \text{ quando } p = 0.5)$$

$$\text{p-valor} = \sum_{r=0}^3 \binom{10}{r} (0.5)^{10-r} (0.5)^r = \sum_{r=0}^3 \frac{10!}{r!(10-r)!} 0.5^{10}$$

$$\text{p-valor} = 0.0010 + 0.0098 + 0.0439 + 0.1172 = 0.1719$$

Logo, não rejeitamos H_0 com um $\alpha = 0.05$.

Teste do Sinal - Exemplo: Calculando no R:

```
x<-3 # "sucessos"  
n<-10 # realizações  
  
pbinom(x, n, p=0.5) # CDF da Binomial.  
  
[1] 0.171875
```

Teste do Sinal - Algumas observações: Nos testes paramétricos é possível obter p-valores no intervalo contínuo $[0, 1]$;

Já no teste do sinal os p-valores podem assumir apenas valores discretos.

No nosso exemplo, com um $n = 10$ e $\alpha = 0.05$, só rejeitaremos H_0 com aquela H_1 caso:

- ▶ r^+ seja igual a 0 $\rightarrow$ p-valor = 0.001;
- ▶ r^+ igual a 1 $\rightarrow$ p-valor = 0.0107.

Teste do Sinal - Algumas observações: Esse teste pode ser utilizado para verificar uma hipótese sobre os quartis.

Por exemplo, o terceiro quartil seria testado com uma binomial com probabilidade de “sucesso” de $p = 0.25$ ou $p = 0.75$ dependendo da H_1 .

Também podemos testar hipóteses sobre os percentis da distribuição.

Teste do Sinal - Exemplo

```
library(BSDA) # package for the sign test
X <- c(49, 58, 75, 110, 112, 132, 151, 276, 281, 362)
SIGN.test(X, md=200, alternative="less")
```

```
One-sample Sign-Test
data: X
s = 3, p-value = 0.1719
alternative hypothesis: true median is less than 200
95 percent confidence interval:
 -Inf 276.5333
sample estimates:
median of x
      122
```

Achieved and Interpolated Confidence Intervals:

	Conf.Level	L.E.pt	U.E.pt
Lower Achieved CI	0.9453	-Inf	276.0000
Interpolated CI	0.9500	-Inf	276.5333
Upper Achieved CI	0.9893	-Inf	281.0000

Teste de Wilcoxon: Também conhecido como “Teste dos postos sinalizados de Wilcoxon”.

Utilizado para testar se uma $H_0 : \theta = \theta_0$ é válida, onde θ é a mediana de uma distribuição contínua **simétrica**.

Premissas:

- ▶ Amostras *iid*;
- ▶ Distribuição contínua;
- ▶ Distribuição Simétrica.

Similar ao Teste do Sinal, mas aqui será considerado o **sinal** e a **magnitude** da distância de cada x_i para θ_0 .

Teste de Wilcoxon: Dada um a.a. $\mathbf{X} = \{x_1, \dots, x_n\}$, deve-se:

1. Calcular a diferença absoluta entre cada x_i e θ_0 , obtendo uma nova a.a. $\mathbf{D} = \{|D_1|, \dots, |D_n|\}$;
2. Assinalar um posto (rank) para cada uma delas em ordem crescente de magnitude, 1 para a menor diferença absoluta, e n para a maior diferença absoluta.
3. Deve-se colocar um sinal de $+$ para diferenças positivas e um sinal de $-$ para diferenças negativas;

Se H_0 for verdadeira, espera-se que o espalhamento dos postos sinalizados sejam similares, i.e., $S_+ = \sum R_i^+ \cong S_- = \sum R_i^-$.

Teste de Wilcoxon - Exemplo: A mudança na frequência cardíaca de 12 indivíduos com idade similar ao mudar da posição “sentado” para “em pé” foi medida:

$$\mathbf{X} = \{-2, 4, 8, 25, -5, 16, 3, 1, 12, 17, 20, 9\}$$

E o teste é $H_0 : \theta = 15$ e $H_1 : \theta \neq 15$.

Deve-se calcular a diferença absoluta entre cada x_i e θ_0 :

$$\mathbf{D} = \{17, 11, 7, 10, 20, 1, 12, 14, 3, 2, 5, 6\}$$

Ordenar os valores absolutos preservando os sinais:

$$\mathbf{S} = \{1, 2, -3, 5, -6, -7, 10, -11, -12, -14, -17, -20\}$$

A soma dos postos positivos é $S_+ = 14$, muito menor que a soma dos postos negativos, $S_- = 64$.

Adaptado de Sprent, P., & Smeeton, N. C. (2000). *Applied nonparametric statistical methods*.

Teste de Wilcoxon - Exemplo:

$$S = \{1, 2, -3, 5, -6, -7, 10, -11, -12, -14, -17, -20\}$$

Existem $2^{12} = 4096$ combinações possíveis dos postos sinalizados.

Estamos interessados na probabilidade de observar uma soma dos postos positivos menor ou igual ao observado, que é o nosso p-valor.

Esse cálculo é dispendioso, entretanto pode-se consultar esse valor nas tabelas, ou ainda ser calculado utilizando softwares.

Existe ainda a formulação apresentada por Wilcoxon¹.

¹Wilcoxon, F. "Individual Comparisons by Ranking Methods." Biometrics 1, 80-83, 1945.

Teste de Wilcoxon - Exemplo:

```
# Wilcoxon test
# Heart rate example

X <- c(-2, 4, 8, 25, -5, 16, 3, 1, 12, 17, 20, 9)

wilcox.test(X, alternative="two.sided", mu=15, exact=TRUE,
            conf.int=TRUE)

Wilcoxon signed rank test

data:  X
V = 14, p-value = 0.05225
alternative hypothesis: true location is not equal to 15
95 percent confidence interval:
 2.5 16.0
sample estimates:
(pseudo)median
          9
```

Teste de Wilcoxon Pareado: O teste pareado é o caso em que as amostras são tomadas aos pares de tal maneira a remover algum efeito indesejado para o experimento.

Basicamente realizamos o teste de hipóteses para a estatística calculada sobre a diferença de cada observação.

O Teste de Wilcoxon pareado é realizado de maneira análoga:

$$\begin{cases} H_0 : \theta_D = 0 \\ H_1 : \theta_D \neq 0 \text{ ou } \theta_D < 0 \text{ ou } \theta_D > 0 \end{cases}$$

Iremos considerar o sinal e a magnitude das diferenças observadas como estatística de teste.

Teste de Wilcoxon Pareado - Exemplo: Considere um experimento com 8 duplas de gêmeos idênticos, em que aleatoriamente, um deles foi para o maternal e o outro ficou em casa.

Ao final do estudo, todas as 16 crianças realizaram o mesmo teste de consciência social.

Resultando no seguinte teste de hipóteses:

$$\begin{cases} H_0 : \theta_D = 0 \\ H_1 : \theta_D > 0 \end{cases}$$

onde θ_D é a mediana da diferença de pontos entre os que frequentaram o maternal e os que não frequentaram.

Adaptado de Sheskin, D. J. (2003). *Handbook of parametric and nonparametric statistical procedures*.

Teste de Wilcoxon Pareado - Exemplo:

```
school<-c(82,69,73,43,58,56,76,65)
home<-c(63,42,74,37,51,43,80,62)
response <- school - home
wilcox.test(response,alternative="greater",conf.int=TRUE)
```

Wilcoxon signed rank test

data: response

V = 32, p-value = 0.02734

alternative hypothesis: true location is greater than 0

95 percent confidence interval:

1 Inf

sample estimates:

(pseudo)median

7.75

Teste da Permutação

Teste para comparar dois processos em que não será assumida uma forma específica para as distribuições que geram os dados.

A escolha da estatística de teste deverá ser baseada no contexto do problema, o que pode ser reforçado pelo conhecimento de qual seria um bom modelo paramétrico a ser aplicado.

Ao comparar dois processos F e G com distribuições de probabilidade diferentes, devemos escolher uma estatística de teste, e.g., $t = \mu_F - \mu_G$ caso as distribuições não sejam muito distantes de uma Normal.

Caso a distribuição não seja simétrica, poderíamos utilizar a diferença das medianas como estatística t .

O teste da permutação é basicamente um teste comparativo.

Estaremos interessados em comparar duas variáveis aleatórias (v.a.) $X \sim f_{\psi_X}$ e $Y \sim f_{\psi_Y}$ relacionadas a dois processos de interesse, onde ψ_X e ψ_Y são os conjuntos de parâmetros das distribuições de probabilidade de X e Y respectivamente.

Esses dois processos geram duas a.a., $\mathbf{X}$ e $\mathbf{Y}$, que são utilizadas para realizar o seguinte teste de hipóteses sobre a igualdade de algum parâmetro específico $\psi_X \in \Psi_X$ e $\psi_Y \in \Psi_Y$:

$$\begin{cases} H_0 : \psi_X = \psi_Y \\ H_1 : \psi_X \neq \psi_Y \end{cases}$$

No caso onde não temos um modelo paramétrico para as v.a. X e Y , teremos que utilizar apenas as a.a. observadas $\mathbf{X}$ e $\mathbf{Y}$.

Se $H_0 : \psi_X = \psi_Y$ for válido, então qualquer permutação entre as m observações de X e as n observações de Y , não irá gerar alterações significativas na nossa estatística de teste t .

Sob H_0 , qualquer uma das $N = n + m$ observações poderia ser originada de X ou Y , i.e., as observações de X e Y poderiam ser, respectivamente, qualquer uma das $\binom{N}{m}$ e das $\binom{N}{n}$ combinações possíveis.

Vamos supor que queremos verificar que não exista diferença nas eficiências médias de dois processos similares.

Nesse caso, $H_0 : \mu_X = \mu_Y$ e estimamos $\hat{\mu}_X = \bar{X}$ e $\hat{\mu}_Y = \bar{Y}$ e podemos utilizar a seguinte estatística para o teste $t = \mu_X - \mu_Y$.

Podemos escrever o p-valor como $P(T \geq \hat{t} | H_0)$. Sob H_0 , qualquer permutação das $N = m + n$ observações não resultará em mudanças significativas na estatística de teste $t = \mu_X - \mu_Y$.

Assim, iremos aproximar o p-valor $= P(T \geq \hat{t} | H_0)$ por p-valor $= P(T^* \geq \hat{t})$, onde T^* é uma v.a. que iremos amostrar através da realização de R permutações entre as a.a. observadas $\mathbf{X}$ e $\mathbf{Y}$.

Iremos realizar R permutações entre as a.a. observadas $\mathbf{X}$ e $\mathbf{Y}$ e para cada permutação calcular a estatística de teste t_r^* , e estimar o p-valor como:

$$\text{p-valor} = \frac{1 + \#\{t_r^* \geq \hat{t}\}}{R + 1}$$

Onde:

- ▶ $\#$ é um indicador de quantidade;
- ▶ t_r^* é a estatística de interesse calculada para as amostras permutadas;
- ▶ R é o numero de permutações realizadas.

Importante: Deve-se utilizar $R \geq 99$. Na prática adotamos valores maiores, como $R = 999$ ou 9999 .

Exemplo: Considere as seguintes observações do tempo de processamento em horas de duas versões de um software:

$\mathbf{X} = \{1.24, 1.38, 1.36, 1.40, 1.38, 1.48, 1.38, 1.48, 1.38, 1.54, 1.56\}$

$\mathbf{Y} = \{1.14, 1.20, 1.30, 1.26, 1.28, 1.18\}$

No caso, queremos verificar se a versão Y resulta em tempos inferiores de processamento:

$$\begin{cases} H_0 : \mu_X - \mu_Y = 0 \\ H_1 : \mu_X - \mu_Y > 0 \end{cases}$$

Adaptado de Ernst, M. D. (2004). Permutation methods: a basis for exact inference. *Statistical Science*, 19(4), 676-685.

Exemplo:

```
X <- c(1.24, 1.38, 1.36, 1.40, 1.38, 1.48, 1.38, 1.48, 1.38, 1.54, 1.5)
Y <- c(1.14, 1.20, 1.30, 1.26, 1.28, 1.18)
t_hat <- mean(X)-mean(Y)
S <- append(X,Y)
set.seed(1) ## for reproducibility
nperm <- 10000
n1 <- length(X)
n2 <- length(Y)
t_perm <- numeric(nperm) ## set aside space for results
for (i in 1:nperm) {
  Sperm <- sample(S, n1+n2)
  Xperm <- Sperm[1:n1]
  Yperm <- Sperm[n1+1:n2]
  t_perm[i] <- mean(Xperm) - mean(Yperm)
}
# H_1: mu_X>mu_y
p_perm = (1 + sum(t_perm >= t_hat))/(1+nperm)


p_perm
[1] 0.00049995
```

Testes de Bootstrap


É uma abordagem computacional baseada em reamostragem.

Considere uma a.a. $\mathbf{X}$ que seja representativa da população, i.e., experimento planejado e executado de maneira satisfatória.

Então podemos fazer **reamostragens com reposição** a partir de $\mathbf{X}$ para obter outras a.a. $\mathbf{X}^*$.



Repetindo R vezes:



Utilizando as a.a. $\{\mathbf{X}_1^*, \dots, \mathbf{X}_R^*\}$ de bootstrap, é possível avaliar como alguma estatística T de interesse se comporta.

O Bootstrap é uma técnica de reamostragem aplicável em diferentes situações:

- ▶ Taxa de erro ou variabilidade;
- ▶ Intervalos de Confiança;
- ▶ Intervalos de Predição;
- ▶ **Testes de Hipótese.**;
- ▶ Regressão.

Importante:

- ▶ Cada amostra de bootstrap $\mathbf{X}^*$ terá tamanho n e será obtida utilizando **sorteio com reposição** das observações em $\mathbf{X}$;
- ▶ Bootstrap **não** significa gerar novos dados;

Em qualquer teste de hipóteses estamos interessados em avaliar uma H_0 conservadora (nenhuma novidade) através de experimentos.

A ideia é verificar a probabilidade de observamos uma estatística $\hat{t}$ tão extrema quanto a calculada a partir de uma a.a. caso $H_0 : t = t_0$ seja de fato verdadeira.

Nesse contexto, iremos fazer uma reamostragem de tal maneira que as condições de H_0 sejam respeitadas e possamos calcular o p-valor.

O teste de Bootstrap possui algumas variações:

- ▶ Utiliza-se as condições de H_0 para fazer reamostragens de uma F_0 e em seguida se compara com o observado nos dados -

Bootstrap paramétrico:

$$\text{p-valor} = P(T \geq t | H_0) = P(T^* \geq t | \hat{F}_0)$$

- ▶ Utiliza-se apenas as observações para realizar as reamostragens de tal maneira a se respeitar H_0 - **Bootstrap não-paramétrico;**

Bootstrap não-paramétrico: Queremos confrontar uma H_0 com uma estatística observada $\hat{t}$.

Iremos realizar o processo de sorteio com reposição a partir de um conjunto de dados que satisfaça H_0 .

Para cada reamostragem realizada, iremos calcular uma estatística t_r^* a partir dos $\mathbf{X}_r^*$.

Como os dados que estamos reamostrando satisfazem H_0 , nosso p-valor será:

$$\text{p-valor} = P(T^* \geq \hat{t})$$

Esse p-valor = $P(T^* \geq t)$ pode ser aproximado por:

$$\text{p-valor} = \frac{1 + \#\{t_r^* \geq \hat{t}\}}{R + 1}$$

Onde:

- ▶ $\#$ é um indicador de quantidade;
- ▶ t_r^* é a estatística de interesse calculada para cada amostra de bootstrap $t_1^*, \dots, t_R^*$;
- ▶ R é o numero de reamostragens realizadas no bootstrap.

Importante: Deve-se utilizar $R \geq 99$. Na prática adotamos valores maiores, como $R = 999$ ou 9999 .

Teste de Bootstrap Não-paramétrico - Exemplo. Duas amostras descrevem medidas do tempo de execução de um mesmo processo em instantes diferentes:

$\mathbf{X} = \{82, 79, 81, 79, 77, 79, 79, 78, 79, 82, 76, 73, 64\}$

$\mathbf{Y} = \{84, 86, 85, 82, 77, 76, 77, 80, 83, 81, 78, 78, 78\}$

O objetivo é verificar se o tempo médio de execução do processo Y ficou mais lento que o X, ou seja:

$$\begin{cases} H_0 : \mu_Y = \mu_X \\ H_1 : \mu_Y > \mu_X \end{cases}$$

Adaptado de Davison, A. C., & Hinkley, D. V. (1997). *Bootstrap methods and their application*.

Teste de Bootstrap Não-paramétrico - Exemplo. Utilizaremos a estatística de teste $t = \bar{Y} - \bar{X}$;

Como as medidas são referentes ao mesmo processo, podemos assumir que as distribuições de probabilidade que originaram as observações possuem o mesmo formato.

Nessas condições é plausível considerar que se H_0 é verdadeira, as distribuições são as mesmas.

Teste de Bootstrap Não-paramétrico - Exemplo.

```
X <- c(82, 79, 81, 79, 77, 79, 79, 78, 79, 82, 76, 73, 64)
Y <- c(84, 86, 85, 82, 77, 76, 77, 80, 83, 81, 78, 78, 78)

t_hat<- mean(Y)-mean(X)
set.seed(112)
n1<-length(X)
n2<-length(Y)
S <- append(X, Y)
R <- 999
t_R <- as.vector(NULL)
for (i in 1:R){ # bootstrap resamples
  XX <- sample(S, n1, replace=TRUE)
  YY <- sample(S, n2, replace=TRUE)
  t_R[i] <- mean(YY)-mean(XX)
}
p_R = (1 + sum(t_R >= t_hat))/(1+R)
> p_R
[1] 0.036
```

Outros Métodos

- ▶ Teste do Sinal Binomial: proporção ou dados categóricos;
- ▶ Teste de Kruskal-Wallis: alternativa não paramétrica ao ANOVA;
- ▶ Teste de Friedman: teste da mediana para um Experimento Completamente Aleatorizado com Blocos;
- ▶ Teste U de Mann-Whitney: diferença na mediana de duas populações;
- ▶ Teste de Kolmogorov-Smirnov: para verificar o ajuste de uma distribuição;
- ▶ Correlação por postos de Spearman: correlação não paramétrica.

Existem muitos outros, uma boa referência é: [Handbook of Parametric and Nonparametric Statistical Procedures](#)

Referências

Principais:

- ▶ Notas de Aula - Moodle
- ▶ D.C. Montgomery, G.C. Runger (2010), *Applied Statistics and Probability for Engineers*, John Wiley & Sons.
- ▶ Sprent, P., & Smeeton, N. C. (2000). *Applied nonparametric statistical methods*. Chapman and Hall/CRC.
- ▶ Sheskin, D. J. (2003). *Handbook of parametric and nonparametric statistical procedures*. Chapman and Hall/CRC.
- ▶ Davison, A. C., & Hinkley, D. V. (1997). *Bootstrap methods and their application*. Cambridge university press.

Adicionais:

- ▶ Feng, C., Wang, H., Lu, N., & Tu, X. M. (2013). Log transformation: application and interpretation in biomedical research. *Statistics in medicine*, 32(2), 230-239.
- ▶ Ernst, M. D. (2004). Permutation methods: a basis for exact inference. *Statistical Science*, 19(4), 676-685.