Planejamento e Análise de Experimentos

11 - Experimento Fatorial

Michel Bessani

Operations Research and Complex Systems Lab.
https://orcslab.github.io/

Departamento de Engenharia Elétrica - DEE

Programa de Pós-Graduação em Engenharia Elétrica - PPGEE

UFMG
UNIVERSIDADE FEDERAL
DE MINAS GERAIS

Belo Horizonte

Sumário

1. Introdução
1.1 Exemplo
2. Experimento Fatorial
2.1 Modelagem Estatística com 2 fatores
2.2 Aplicando no Exemplo
2.3 Comparações Múltiplas
2.4 Experimentos com mais de 2 fatores
2.5 Exemplo com mais de 2 fatores
3. Referências

Introdução

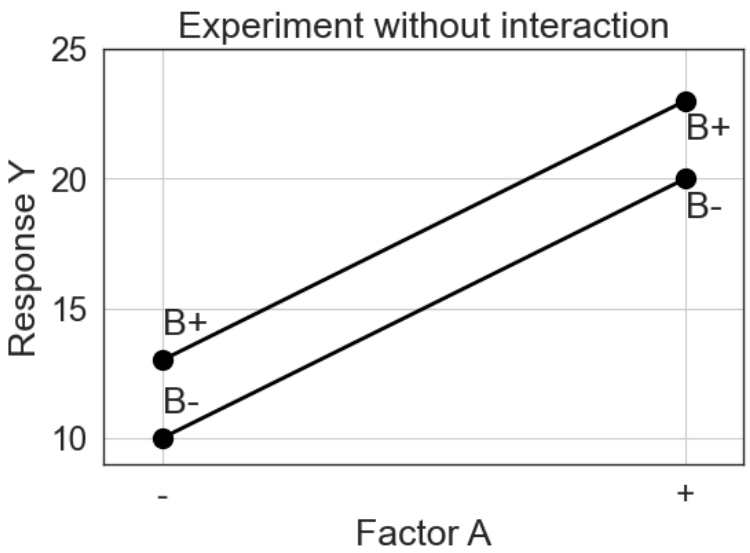
A maioria dos experimentos envolvem **mais de um fator** de interesse.

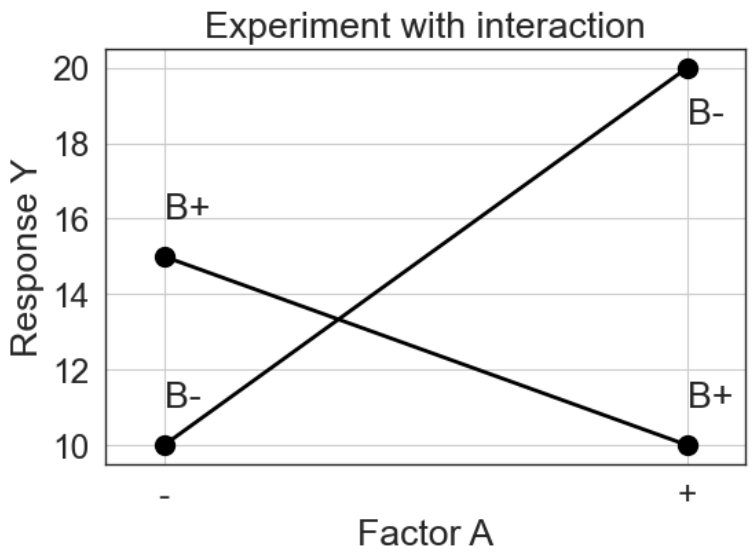
Uma estratégia efetiva para analisar os efeitos dos fatores, tanto individualmente como as interações, é realizando um **experimento fatorial**, i.e., todas as combinações de todos os níveis de fatores serão avaliadas.

Nesse contexto, o **efeito principal** será a mudança média gerada na variável de resposta devido à mudança nos níveis de um fator.

Há **efeito de interação** quando a resposta a mudanças de um fator depende do nível de outro fator.

As figuras abaixo ilustram dois experimentos, um sem interação entre os fatores e outro com a interação entre os fatores.





Esses tipos de gráficos são úteis para interpretar interações significativas e para relatar resultados para pessoas sem treinamento estatístico.

Introdução:
Exemplo

Dois engenheiros querem investigar os fatores que podem afetar a corrente elétrica demandada por motores monofásicos utilizados para ventilação em uma granja industrial[1].

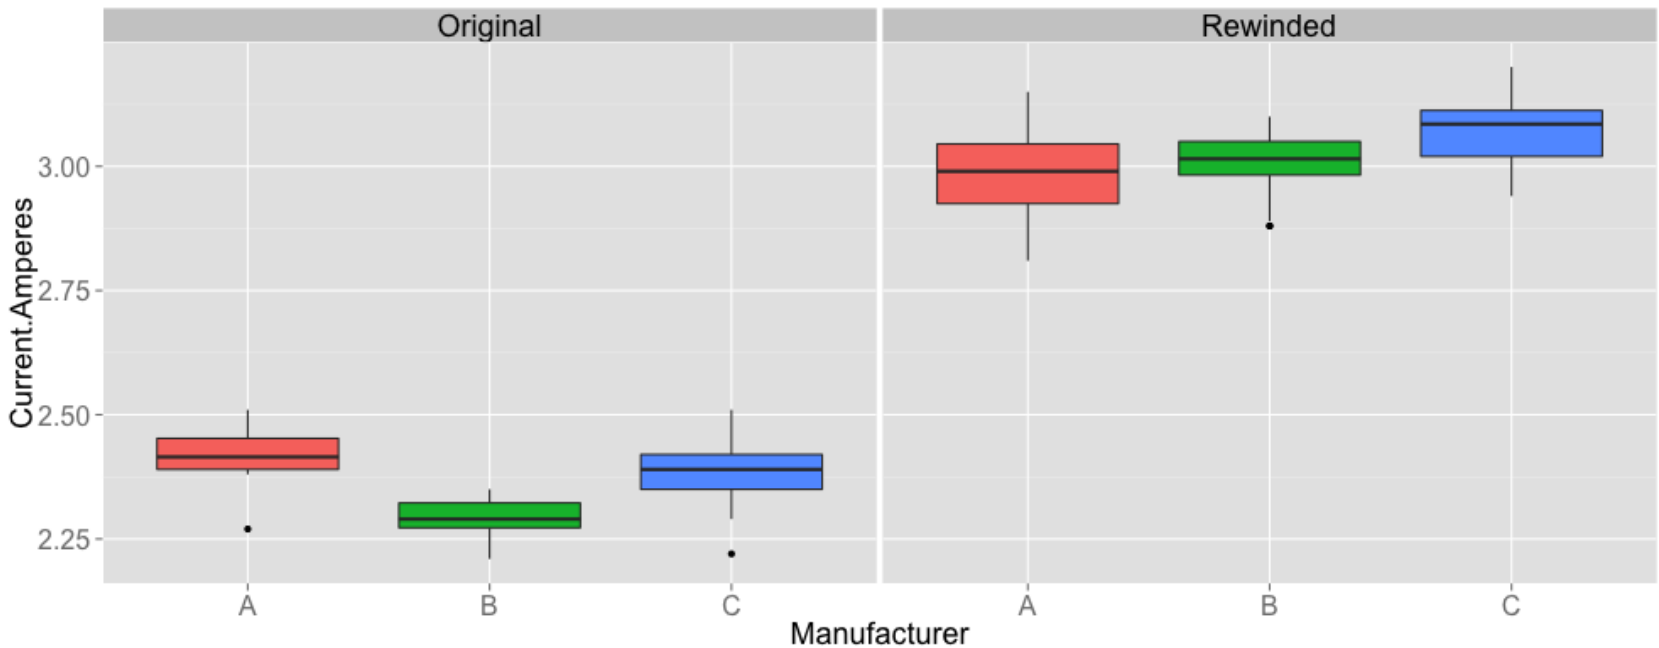
Observações anteriores sugerem que a corrente varia consideravelmente entre motores, e o conhecimento específico sugere dois fatores candidatos para explicar tal variabilidade:

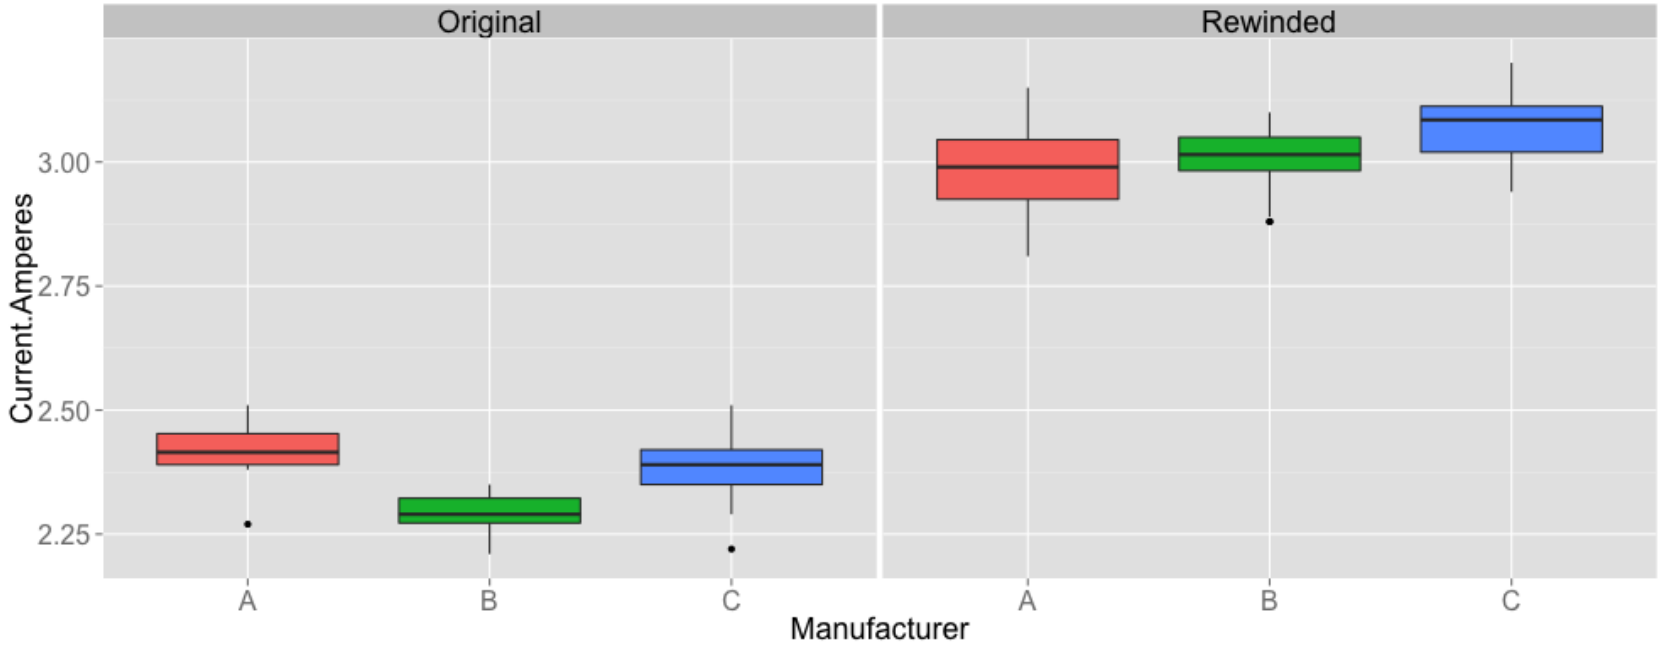
1. **Fabricante**: A, B ou C;
2. **Estado**: Original ou Rebobinado.

Para investigarem essa questão, os engenheiros decidiram amostrar 40 motores de cada fabricante, sendo 20 originais e 20 rebobinados.

[1] Adaptado do projeto final do curso de Planejamento e Análise de Experimentos de M.H.Costa e T.L. Vieira, PPGEE-UFMG, Novembro de 2013. Os dados usados nesse exemplo não são necessariamente os originais.

```
> data <- read.table("../data files/motors.txt", header = TRUE)
> library(ggplot2)
> p <- ggplot(data, aes(x = Manufacturer, y = Current.Amperes,
                        fill = Manufacturer))
> p + geom_boxplot() + facet_grid(.~State) + ...
```





O gráfico sugere uma diferença entre os estados dos motores, mas sem evidências fortes sobre o efeito do fator Fabricante. Além disso, qualquer interação entre os fatores parece ter um efeito pequeno.

Vamos assumir que os engenheiros do exemplo querem $\alpha = 0.05$, $\beta = 0.2$ e $\delta^* = 0.1$ A.

Experimento Fatorial

Experimento Fatorial:
Modelagem Estatística com 2 fatores

Teremos para um experimento fatorial balanceado e de efeitos fixos:

- a níveis do fator **A**;
- b níveis do fator **B**;
- n repetições em cada combinação de níveis;
- Coleta de observações completamente aleatorizada.

O modelo de efeitos para um conjunto de observações de acordo com esse planejamento pode ser expresso pelo seguinte modelo linear:

$$y_{ijk} = \mu + \tau_i + \beta_j + (\tau\beta)_{ij} + \epsilon_{ijk} \begin{cases} i = 1, \ldots, a \\ j = 1, \ldots, b \\ k = 1, \ldots, n \end{cases}$$

$$y_{ijk} = \mu + \tau_i + \beta_j + (\tau\beta)_{ij} + \epsilon_{ijk} \begin{cases} i = 1, \ldots, a \\ j = 1, \ldots, b \\ k = 1, \ldots, n \end{cases}$$

Como anteriormente, iremos tratar os efeitos como desvios em relação à média global.

Logo, por construção:

$$\sum_{i=1}^{a} \tau_i = 0 \qquad \sum_{j=1}^{b} \beta_j = 0$$

$$\sum_{i=1}^{a} (\tau\beta)_{ij} = \sum_{j=1}^{b} (\tau\beta)_{ij} = 0$$

O experimento fatorial surge quando queremos modelar os efeitos principais e as interações entre múltiplos fatores.

Testamos as seguintes hipóteses para o caso de dois fatores:

$$\text{Fator } A\text{, efeito principal: } \begin{cases} H_0 : \tau_i = 0, \ \forall i \\ H_1 : \exists \tau_i \neq 0 \end{cases}$$

$$\text{Fator } B\text{, efeito principal: } \begin{cases} H_0 : \beta_j = 0, \ \forall j \\ H_1 : \exists \beta_j \neq 0 \end{cases}$$

$$AB\text{, efeito da interação: } \begin{cases} H_0 : (\tau\beta)_{ij} = 0, \ \forall i,j \\ H_1 : \exists (\tau\beta)_{ij} \neq 0 \end{cases}$$

As estatísticas de teste dessas hipóteses serão derivadas pelo particionamento da variabilidade total em partes específicas[2]:

$$SS_T = \sum_{i=1}^{a}\sum_{j=1}^{b}\sum_{k=1}^{n}(y_{ijk} - \bar{y}_{...})^2$$

$$SS_T = \underbrace{bn\sum_{i=1}^{a}(\bar{y}_{i..} - \bar{y}_{...})^2}_{SS_A} + \underbrace{an\sum_{j=1}^{b}(\bar{y}_{.j.} - \bar{y}_{...})^2}_{SS_B}$$

$$+ \underbrace{n\sum_{i=1}^{a}\sum_{j=1}^{b}(\bar{y}_{ij.} - \bar{y}_{i..} - \bar{y}_{.j.} + \bar{y}_{...})^2}_{SS_{AB}} + \underbrace{\sum_{i=1}^{a}\sum_{j=1}^{b}\sum_{k=1}^{n}(y_{ijk} - \bar{y}_{ij.})^2}_{SS_E}$$

[2] É necessário $n \geq 2$ para distinguir SS_{AB} de SS_E.

Os quadrados médios são calculados da forma usual:

$$MS_A = \frac{SS_A}{a-1}$$

$$MS_B = \frac{SS_B}{b-1}$$

$$MS_{AB} = \frac{SS_{AB}}{(a-1)(b-1)}$$

$$MS_E = \frac{SS_E}{ab(n-1)}$$

E os valores esperados dos quadrados médios são:

$$E\left[MS_A\right] = \sigma^2 + \frac{bn\sum_{i=1}^{a}\tau_i^2}{a-1}$$

$$E\left[MS_B\right] = \sigma^2 + \frac{an\sum_{j=1}^{b}\beta_j^2}{b-1}$$

$$E\left[MS_{AB}\right] = \sigma^2 + \frac{n\sum_{i=1}^{a}\sum_{j=1}^{b}(\tau\beta)_{ij}^2}{(a-1)(b-1)}$$

$$E\left[MS_E\right] = \sigma^2$$

Se a premissa, ϵ_{ijk} i.i.d. $\mathcal{N}(0, \sigma^2)$, for validada, então as frações:

$$F_0^{(A)} = \frac{MS_A}{MS_E} \qquad F_0^{(B)} = \frac{MS_B}{MS_E} \qquad F_0^{(AB)} = \frac{MS_{AB}}{MS_E}$$

são distribuídas, sob as suas respectivas hipóteses nulas, como v.a. F.

Cada qual com seus respectivos graus de liberdade, $df_A = a - 1$, $df_B = b - 1$, $df_{AB} = (a-1)(b-1)$ e $df_E = ab(n-1)$.

As hipóteses podem ser testadas comparando os valores F_0 obtidos com os valores críticos $F_{1-\alpha;df_1;df_2}$.

Experimento Fatorial: Aplicando no Exemplo

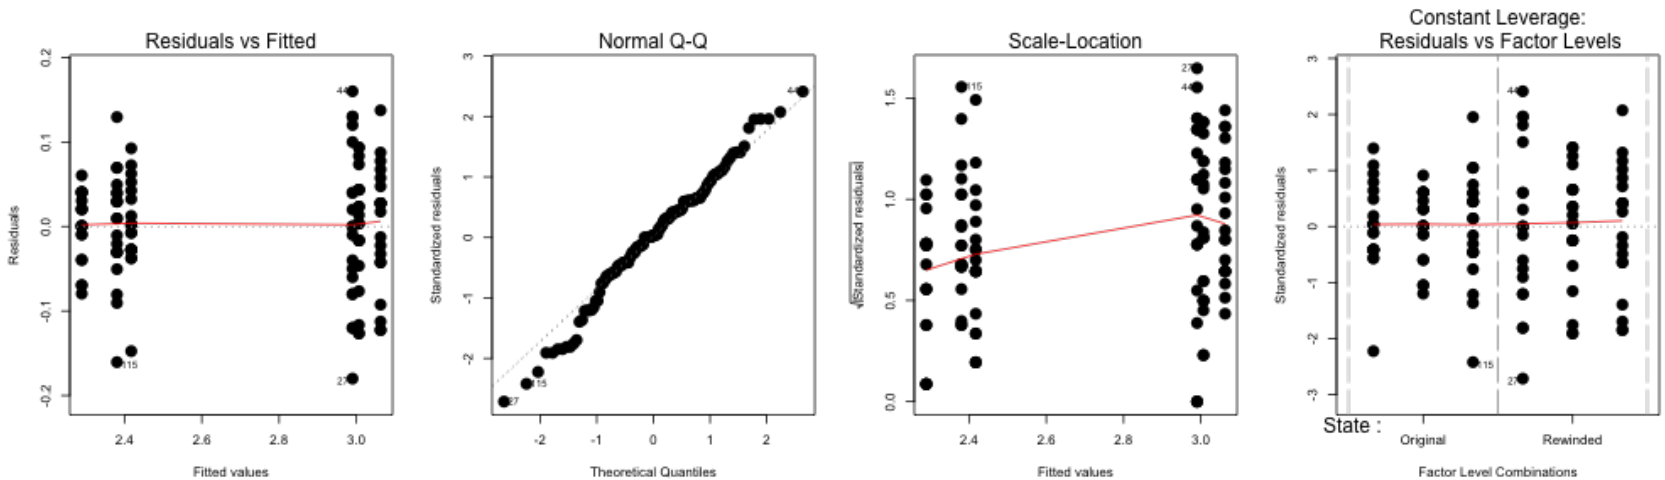
```
> model <- aov(Current.Amperes~State*Manufacturer,
+              data = data)
> summary(model)
                    Df Sum Sq Mean Sq F value   Pr(>F)
State                1 12.956  12.956 2798.41  < 2e-16 ***
Manufacturer         2  0.118   0.059   12.71 1.04e-05 ***
State:Manufacturer   2  0.114   0.057   12.27 1.49e-05 ***
Residuals          114  0.528   0.005
---

> summary.lm(model)$r.squared
[1] 0.9615174
```

As premissas de normalidade e homoscedasticidade podem ser verificadas analisando os resíduos, similar ao feito no one-way ANOVA:

```
> shapiro.test(model$residuals)
W = 0.9857, p-value = 0.2392

> fligner.test(Current.Amperes ~ interaction(State, Manufacturer),
+              data = data)
med chi-squared = 10.1721, df = 5, p-value = 0.0705
```



A independência deve ser sustentada pelo planejamento experimental.

Experimento Fatorial: Comparações Múltiplas

Se o teste de hipóteses indicar a existência de efeitos significativos, i.e., rejeitarmos H_0 para algum dos efeitos principais ou efeitos da interação, pode-se realizar as comparações pareadas entre os níveis para investigar as diferenças.

Quando o efeito da interação não é significativo, as comparações entre os níveis dos fatores podem ser feitas de forma direta utilizando os efeitos médios estimados.

Por exemplo, a estatística de teste para comparar os efeitos médios dos níveis 2 e 3 do fator A pode ser calculada como:

$$t_0 = \frac{\bar{y}_{2\cdot\cdot} - \bar{y}_{3\cdot\cdot}}{\sqrt{2\frac{MS_E}{n'}}}$$

onde n' é o número de repetições específicas para a comparação considerada.

De forma geral para experimentos balanceados:

$$t_0 = \frac{\Delta\bar{y}}{\sqrt{2\frac{MS_E}{n'}}}$$

Para comparações de níveis de fatores (efeitos principais), o valor de n' é o número total de observações nesse nível.

Para comparação entre médias das combinações de níveis, n' será o número de observações em cada grupo de combinação de níveis.

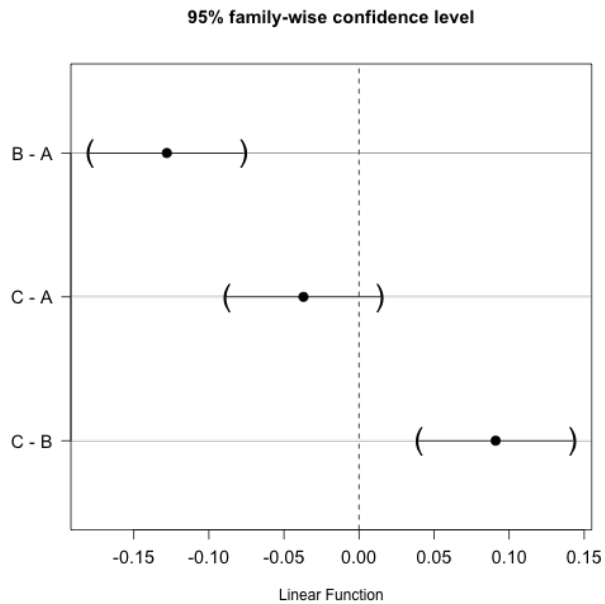
```
> replications(Current ~ State*Manufacturer,
+              data = data)
            State       Manufacturer State:Manufacturer
               60                 40                  20
```

Além disso, o α também deve ser ajustado para evitar os efeitos do aumento da taxa de Erros do Tipo-I através das estratégias de comparações múltiplas.

Por exemplo, realizar uma comparação de *todos contra todos* utilizando o método de Tukey resulta, para o fator Fabricante:

```
> mcp.manuf <- glht(model, linfct = mcp(Manufacturer = "Tukey"))
Warning message:
In mcp2matrix(model, linfct = linfct) :
  covariate interactions found
  -- default contrast might be inappropriate
```

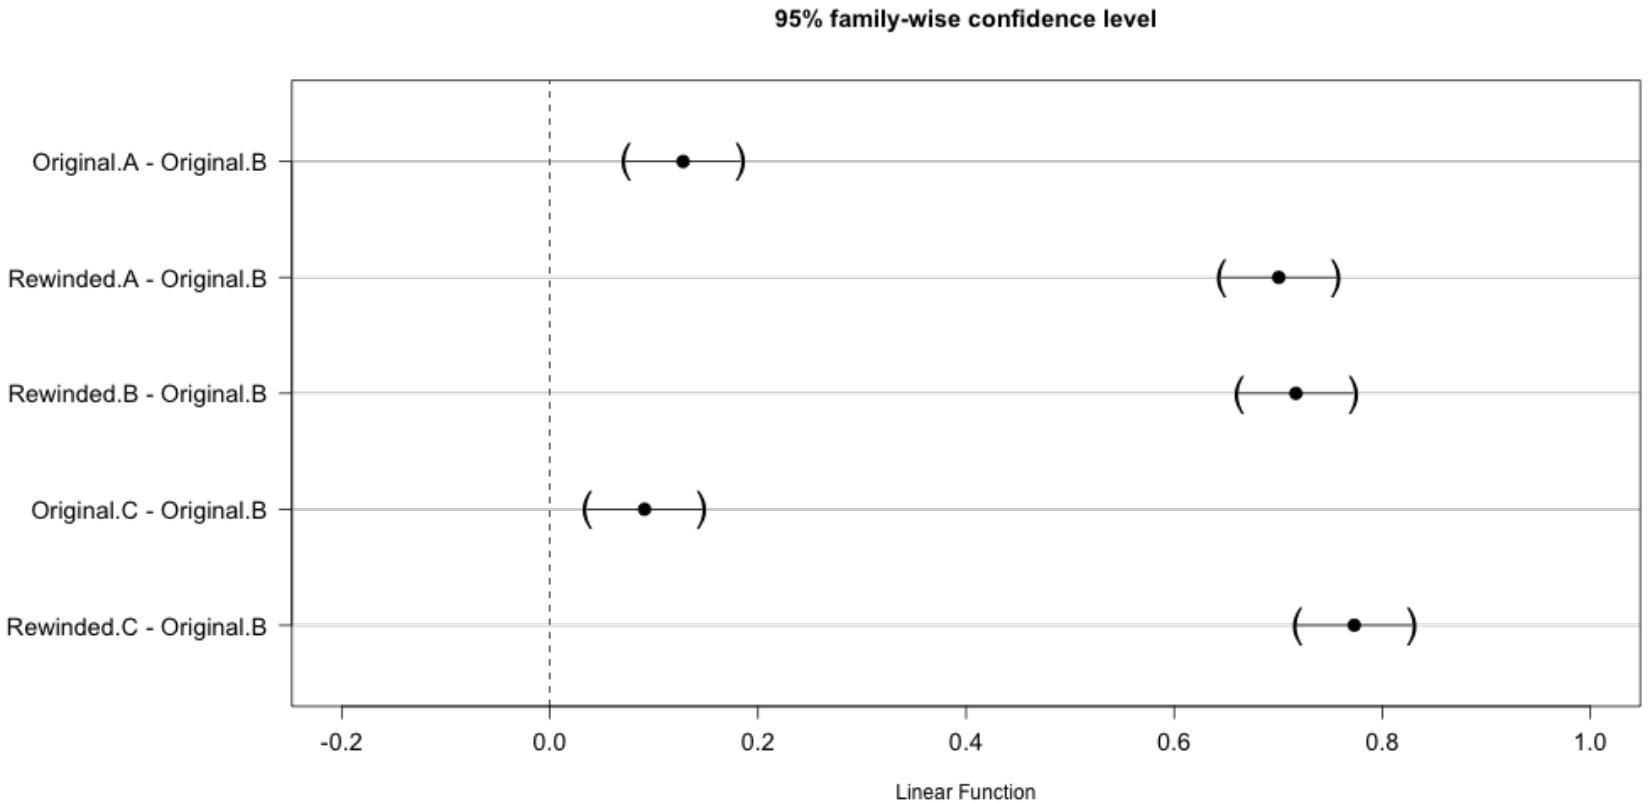
```
> plot(confint(mcp.manuf),
+      cex.axis   = 1.2,
+      cex        = 2)
```



A comparação entre médias das combinações de níveis demanda um tratamento dos dados e do modelo. Assumindo que queremos comparar todos os grupos contra o motor do fabricante B em estado original:

```
> # Create meta-factor for interaction groups
> interfac <- with(data,
+                  interaction(State, Manufacturer))
>
> # Use group "Original.B" as the reference
> interfac <- relevel(interfac, ref = "Original.B")
>
> # ReFit model
> model2 <- aov(Current.Amperes ~ interfac,
+               data = data)
>
> # Multiple comparisons
> # Dunnett method is used when a reference is known
> mcp.inter <- glht(model2,
+                   linfct = mcp(interfac = "Dunnett"))
```

```
> par(mar = c(5,12,4,2))
> plot(confint(mcp.inter), xlim = c(-0.2, 1), cex.axis = 1.2, cex = 2)
```



Para esse exemplo, os engenheiros possuem dados suficientes para realizarem recomendações.

Por exemplo, os dados indicam que os motores rebobinados resultam em maiores consumos de corrente, o que a depender das condições operacionais, pode resultar em custos adicionais, e.g., instalação elétrica e equipamentos de proteção.

Os engenheiros podem avaliar fatores econômicos, operacionais e de desempenho para chegarem em conclusões como:

- Substituir gradualmente os motores por novos do fabricante B;
- É melhor descartar os motores do que realizar o rebobinamento;
- Se alguma outra alternativa de rebobinamento estiver disponível, então vale a pena realizar uma avaliação.

Experimento Fatorial:
Experimentos com mais de 2 fatores

No caso geral de um experimento fatorial, teremos:

- a níveis do fator **A**;
- b níveis do fator **B**;
- c níveis do fator **C**;
- ....

Se considerarmos um experimento com $n \geq 2$ repetições para cada combinação dos níveis, o número total de observações necessárias será $abc \ldots n$.

A modelagem e a análise desses experimentos é facilmente obtida através da generalização do experimento com 2 fatores.
Por exemplo, para 3 fatores:

$$
\begin{aligned}
y_{ijkl} = \mu & && \longleftarrow \text{Média global} \\
& + \tau_i + \beta_j + \gamma_k && \longleftarrow \text{Efeitos principais} \\
& + (\tau\beta)_{ij} + (\tau\gamma)_{ik} + (\beta\gamma)_{jk} && \longleftarrow \text{Interações de 2ª ordem} \\
& + (\tau\beta\gamma)_{ijk} && \longleftarrow \text{Interações de 3ª ordem} \\
& + \epsilon_{ijkl} && \longleftarrow \text{Resíduo} \\
& i = 1, \ldots, a; \\
& j = 1, \ldots, b; \\
& k = 1, \ldots, c; \\
& l = 1, \ldots, n;
\end{aligned}
$$

Soma dos quadrados totais e efeitos principais:

$$SS_T = \sum_{i=1}^{a}\sum_{j=1}^{b}\sum_{k=1}^{c}\sum_{l=1}^{n} y_{ijkl}^2 - \frac{y_{....}^2}{abcn}$$

$$SS_A = \frac{1}{bcn}\sum_{i=1}^{a} y_{i...}^2 - \frac{y_{....}^2}{abcn}$$

$$SS_B = \frac{1}{acn}\sum_{j=1}^{b} y_{.j..}^2 - \frac{y_{....}^2}{abcn}$$

$$SS_C = \frac{1}{abn}\sum_{k=1}^{c} y_{..k.}^2 - \frac{y_{....}^2}{abcn}$$

Soma dos quadrados das interações de 2º ordem:

$$SS_{AB} = \frac{1}{cn}\sum_{i=1}^{a}\sum_{j=1}^{b} y_{ij\cdot\cdot}^2 - \frac{y_{\cdot\cdot\cdot\cdot}^2}{abcn} - SS_A - SS_B$$

$$SS_{AC} = \frac{1}{bn}\sum_{i=1}^{a}\sum_{k=1}^{c} y_{i\cdot k\cdot}^2 - \frac{y_{\cdot\cdot\cdot\cdot}^2}{abcn} - SS_A - SS_C$$

$$SS_{BC} = \frac{1}{an}\sum_{j=1}^{b}\sum_{k=1}^{c} y_{\cdot jk\cdot}^2 - \frac{y_{\cdot\cdot\cdot\cdot}^2}{abcn} - SS_B - SS_C$$

Soma dos quadrados das interações de 3º ordem e resíduos

$$SS_{ABC} = \frac{1}{n}\sum_{i=1}^{a}\sum_{j=1}^{b}\sum_{k=1}^{c} y_{ijk\cdot}^2 - \frac{y_{....}^2}{abcn} - SS_A - SS_B - SS_C - SS_{AB} - SS_{AC} - SS_{BC}$$

$$SS_E = SS_T - SS_A - SS_B - SS_C - SS_{AB} - SS_{AC} - SS_{BC} - SS_{ABC}$$

Experimento Fatorial:
Exemplo com mais de 2 fatores

A intervenção cirúrgica padrão para o tratamento da catarata consiste na remoção do cristalino (é uma lente) e no implante de uma lente artificial intraocular.

Essas lentes artificiais intraoculares são geralmente manufaturadas utilizando um torno CNC de alta precisão em que uma peça circular de material biocompatível é esculpida na forma de lente desejada com uma ferramenta de corte de diamante.

Antes da comercialização, cada lente é testada quanto à conformidade com suas propriedades ópticas, e as que não atendem às especificações exigidas são descartadas.

Com base em seu conhecimento desse processo, dois engenheiros projetaram um experimento para a investigação preliminar dos fatores influentes na porcentagem de lentes que atendem às especificações[3].

Três fatores foram selecionados para este estudo preliminar, cada um com dois níveis.

Os recursos alocados para o estudo foram suficientes para a execução de exatamente oito lotes de lentes - ou seja, uma única réplica para cada combinação de níveis.

[3] Adaptado do projeto final do curso de Planejamento e Análise de Experimentos de L.M. Carvalho e D.F. Filgueiras, PPGEE-UFMG, Junho de 2013. Os dados usados nesse exemplo não são necessariamente os originais.

Fatores e níveis:

- Tempo do torno (em minutos): $[2.35; 3.15]$;
- Tempo de polimento (em dias): $[5; 7]$;
- Idade da ferramenta de corte (em ciclos): $[\approx 400; \approx 1200]$;

Para cada combinação de níveis, foi produzido um lote (unidade experimental) de 30 lentes.

A proporção de lentes em conformidade com as especificações em cada lote foi registrada como a variável de resposta.

O experimento foi conduzido de forma totalmente aleatória e parcialmente cego, ou seja, os torneiros mecânicos e inspetores técnicos não sabiam com qual combinação dos níveis dos tratamentos estavam lidando.

O nível de significância foi definido como $\alpha = 0.05$, e os pesquisadores estavam interessados em detectar quaisquer efeitos iguais ou maiores que 0.1 com um poder de 0.8.

Uma vez que temos apenas uma observação por combinação dos níveis, não temos graus de liberdade suficiente para calcular o MS_E. Consequentemente, o teste de hipóteses completo, i.e., efeitos principais e interações, é infactível.

```
> data <- read.table("../data files/lio.txt", header = TRUE)

> model<-aov(Conf.rate ~ .^3, data = data)
> summary(model)
                                          Df Sum Sq Mean Sq
CNCTime.min                                1 0.5151  0.5151
PolTime.days                               1 0.0861  0.0861
ToolAge.cycles                             1 0.0105  0.0105
CNCTime.min:PolTime.days                   1 0.0036  0.0036
CNCTime.min:ToolAge.cycles                 1 0.0001  0.0001
PolTime.days:ToolAge.cycles                1 0.0001  0.0001
CNCTime.min:PolTime.days:ToolAge.cycles    1 0.0036  0.0036
```

Para realizar o teste, são necessários graus de liberdade para o termo do resíduo. Nesses casos com uma única repetição, a abordagem mais usual é descartar os termos com menor influência. Mas quais descartar?

Uma boa forma de proceder nesses casos é começar removendo os termos das interações de maior ordem do modelo, dessa forma esses termos são absorvidos no MS_E.

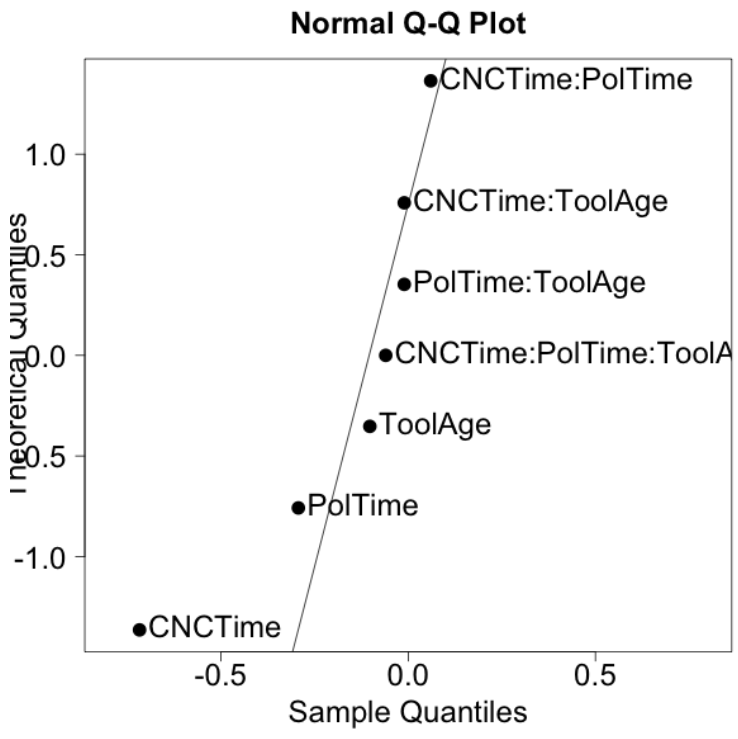
Essa heurística é baseada no princípio da esparsidade, a qual indica que os sistemas são dominados por efeitos individuais e de baixa ordem.

Uma forma qualitativa de verificar a possibilidade de exclusão de alguns efeitos é a análise de um gráfico conhecido como gráfico de efeitos de Daniel, que consiste em plotar estimadores de efeito obtidos de um modelo saturado em um gráfico QQ normal.

Efeitos fortes aparecerão como *outliers*, enquanto efeitos fracos ou insignificantes aparecerão em torno da linha da Normal. Examinando este gráfico podemos obter um modelo simplificado, contendo apenas os efeitos relevantes. Estamos assumindo que as interações excluídas sejam desprezíveis

Os gráficos de Daniel funcionam apenas em experimentos com 2 níveis por fator (planejamentos 2^k).

```
> effect.est <- as.numeric(model$effects[-1])
> qq.text    <- rownames(summary.aov(model)[[1]])
> qq.obj     <- qqnorm(effect.est, datax = TRUE, ...)
> qqline(effect.est, datax = TRUE)
> text(qq.obj$x, qq.obj$y, labels = qq.text,...)
```



O gráfico sugere que os efeitos de maior ordem possuem pouca influência.

O fator CNCTime parece ser o mais relevante sendo o PolTime o segundo mais relevante.

Ao descartarmos os termos de maior ordem, podemos ajustar um modelo simplificado com apenas os efeitos principais:

```
> model2 <- aov(Conf.rate ~ ., data = data)
> summary(model2)
            Df Sum Sq Mean Sq F value   Pr(>F)
CNCTime      1 0.5151  0.5151 276.570 7.66e-05 ***
PolTime      1 0.0861  0.0861  46.235  0.00244 **
ToolAge      1 0.0105  0.0105   5.644  0.07634 .
Residuals    4 0.0074  0.0019

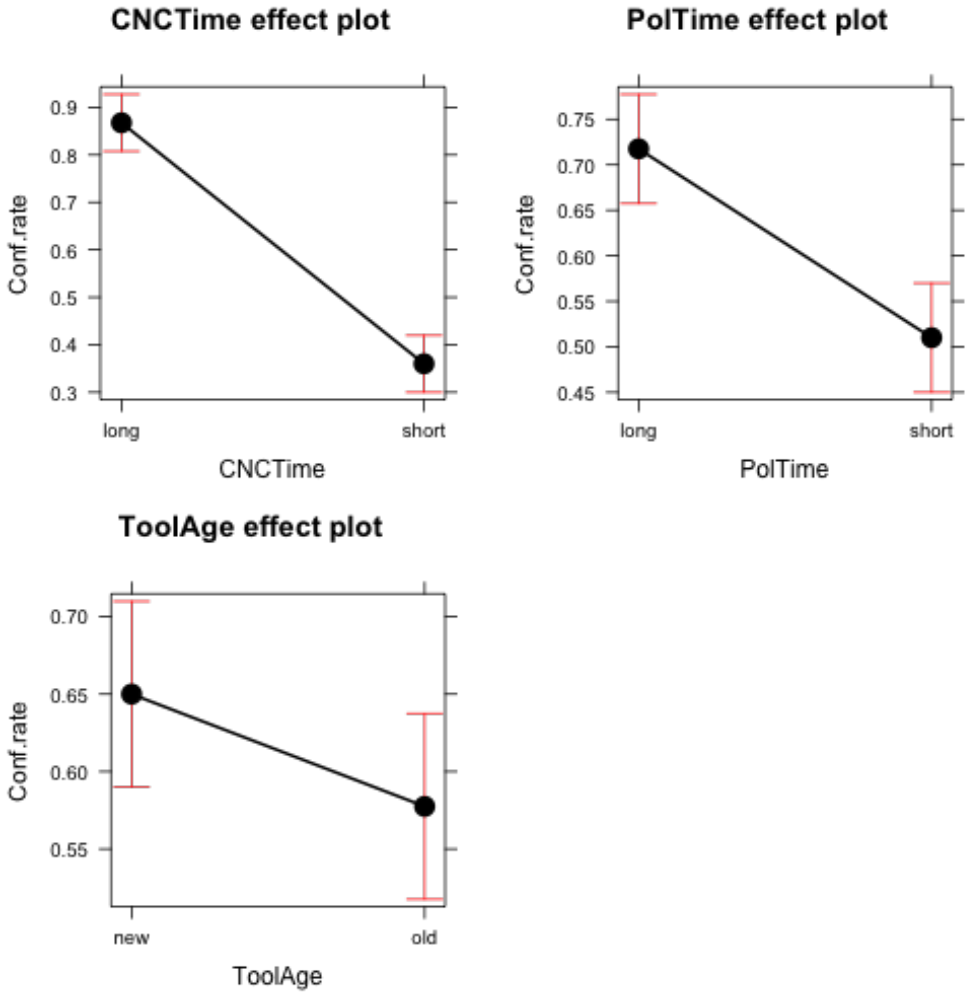
> summary.lm(model2)$r.squared
[1] 0.9879681

> shapiro.test(model2$residuals)
W = 0.9271, p-value = 0.4902
```

```
> summary(glht(model2, linfct = mcp(CNCTime = "Tukey")))
Linear Hypotheses:
                   Estimate Std. Error t value Pr(>|t|)
short - long == 0 -0.50750    0.03052  -16.63 7.66e-05 ***

> summary(glht(model2, linfct = mcp(PolTime = "Tukey")))
Linear Hypotheses:
                   Estimate Std. Error t value Pr(>|t|)
short - long == 0 -0.20750    0.03052    -6.8  0.00244 **
```

```
> library(effects)
> lio.effs <- allEffects(model2)
> plot(lio.effs)
```



O efeito de maior impacto na qualidade do processo é o tempo do torno. A proporção de lentes em conformidade com as especificações vai de 0.36 a 0.87, o que sugere fortemente o uso de tempos de torno maiores como uma boa estratégia.

O tempo de polimento também apresentou impacto significativo, com um salto de 0.51 (5 dias) para 0.72 (7 dias) na proporção de lentes em conformidade.

Não foi detectada diferença significativa entre ferramentas de corte "antigas" e "novas". Isso pode ter ocorrido devido à ausência de efeito, ou devido ao baixo tamanho amostral empregado neste teste.

Provavelmente é interessante explorar mais os tempos de torno CNC e incluir considerações de custo de fabricação nesta discussão.

Blocagem em Experimentos Fatoriais?

A estratégia de bloquear o efeito de um fator indesejável pode ser feita em um experimento fatorial de forma similar ao caso com um único fator de interesse.

No RCBD, cada bloco contém uma observação para cada combinação dos níveis dos fatores.

Os aspectos de modelagem e análise podem ser facilmente derivados combinando essa aula com a de blocagem.

Referências

- D.C. Montgomery, *Design and Analysis of Experiments*, Ch.4-5, 8th Edition, John Wiley & Sons, 2013.

- Felipe Campelo (2018), *Lecture Notes on Design and Analysis of Experiments*. Online: `http://git.io/v3Kh8` Version 2.12; Creative Commons BY-NC-SA 4.0.